# PENERAPAN *ARTIFICIAL NEURAL NETWORK* DENGAN ALGORITMA *BACKPROPAGATION* UNTUK MEMPREDIKSI HARGA SAHAM PT BANK RAKYAT INDONESIA (PERSERO) TBK

**TUGAS CASED BASED LEARNING**

Diajukan untuk melengkapi salah satu syarat guna memperoleh
nilai tugas pada mata kuliah Data Mining di Program Studi Statistika
Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Islam Bandung


Oleh:

| | |
|---|---|
| Khalisha Azzahra | (10060122005) |
| Haya Nailah Ramadhaniah | (10060122009) |
| Keysha Jauzi Althaff | (10060122019) |

**PROGRAM STUDI STATISTIKA**
**FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM**
**UNIVERSITAS ISLAM BANDUNG**


**2026**

# ABSTRAK

Pergerakan harga saham yang fluktuatif menyebabkan prediksi harga saham menjadi hal yang penting dalam pengambilan keputusan investasi. Penelitian ini bertujuan untuk membangun dan mengevaluasi model *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* dalam memprediksi harga penutupan saham PT Bank Rakyat Indonesia (Persero) Tbk (BBRI.JK) yang telah disesuaikan. Data yang digunakan merupakan data sekunder berupa harga saham bulanan periode Januari 2020 hingga Desember 2024 yang diperoleh dari *Yahoo Finance*, dengan total sebanyak 60 observasi. Variabel *input* yang digunakan dalam penelitian ini meliputi *Open, High, dan Low*, dan *Volume* sedangkan variabel output yang diprediksi adalah *Adjusted Close*. Tahapan penelitian meliputi analisis deskriptif data, *preprocessing* (*data selection, data cleaning*, dan normalisasi), pembagian *data training* dan *data testing*, perancangan arsitektur ANN, inisialisasi bobot awal, pelatihan model menggunakan algoritma *Backpropagation*, serta evaluasi kinerja model. Hasil penelitian menunjukkan bahwa model ANN dengan satu *hidden layer* yang terdiri dari tiga neuron mampu memberikan kinerja prediksi yang baik, ditunjukkan oleh nilai error yang relatif kecil, dengan *Mean Squared Error* (MSE) sebesar 29.323,37 dan *Mean Absolute Percentage* Error (MAPE) sekitar 3%. Hasil tersebut menunjukkan bahwa model ANN *Backpropagation* memiliki kemampuan yang baik dalam memprediksi harga penutupan saham BRI yang telah disesuaikan dan berpotensi digunakan sebagai alat bantu dalam analisis dan pengambilan keputusan investasi.

**Kata Kunci: Prediksi Harga Saham BRI; *Artificial Neural Network*; *Backpropagation*.**

# KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT., atas segala rahmat, hidayah, serta karunia-Nya sehingga penulis dapat menyelesaikan Laporan Mata Kuliah *Data Mining* dengan judul "Penerapan *Artificial Neural Network* dengan Algoritma *Backpropagation* untuk Memprediksi Harga Saham PT Bank Rakyat Indonesia (Persero) Tbk" sebagai salah satu syarat tugas pengganti Ujian Akhir Semester pada Program Studi Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Islam Bandung. Penyusunan laporan ini tidak terlepas dari bantuan, dorongan, dan bimbingan dari berbagai pihak. Oleh karena itu, dengan segala kerendahan hati, penulis ingin menyampaikan rasa terima kasih kepada:

1. Allah SWT yang telah memberikan kesehatan dan kesempatan kepada penulis untuk menyelesaikan Laporan Mata Kuliah *Data Mining* ini.
2. Orang tua dan keluarga yang senantiasa mendoakan dan memberikan dukungan baik moral maupun materiil.
3. Bapak Ilham Faishal Mahdy S.Stat., M.Stat. dan Ibu Reny Rian Marliana, S.Si., M.Stat. selaku dosen pengampu mata kuliah *Data Mining.*

Penulis menyadari bahwa laporan ini mungkin masih terdapat kekurangan dan kesalahan, baik dalam penulisan maupun penyusunan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan. Semoga laporan ini dapat memberikan manfaat bagi pembaca dan semua pihak yang berkepentingan. Akhir kata, penulis mengucapkan terima kasih atas perhatian dan kerjasama yang diberikan.

Bandung, 15 Januari 2026

Penulis

# DAFTAR ISI

**ABSTRAK** ..... **II**
**KATA PENGANTAR** ..... **III**
**DAFTAR ISI** ..... **IV**
**DAFTAR TABEL** ..... **VI**
**DAFTAR GAMBAR** ..... **VII**
**DAFTAR LAMPIRAN** ..... **VIII**
**BAB I PENDAHULUAN** ..... **1**
1.1 Latar Belakang ..... 1
1.2 Rumusan Masalah ..... 3
1.3 Tujuan Penelitian ..... 3
1.4 Manfaat Penelitian ..... 3
1.5 Batasan Penelitian ..... 3
1.6 Sistematika Penulisan ..... 4
**BAB II TINJAUAN PUSTAKA** ..... **5**
2.1 Penelitian Terdahulu ..... 5
2.2 Harga Saham ..... 7
2.3 Harga Penutupan yang Disesuaikan (*Adjusted Close*) ..... 7
2.4 Data *Preprocessing* ..... 8
2.4.1 Data *Cleaning* ..... 8
2.4.2 Normalisasi Data ..... 8
2.5 Analisis Deskriptif ..... 8
2.6 *Artificial Neural Network* ..... 10
2.7 Struktur Jaringan *Artificial Neural Network* ..... 11
2.8 Arsitektur Artificial Neural Network ..... 11
2.9 Algoritma *Backpropagation* ..... 13
2.9.1 Proses ANN *Backpropagation* ..... 13
2.9.2 Fungsi Aktivasi ..... 14
2.9.3 Pengujian Akurasi dan *Error* ..... 14
2.10 Prediksi/Peramalan ..... 14
2.11 *Overfitting* dan *Underfitting* ..... 14
2.12 Kerangka Berpikir ..... 15

**BAB III METODOLOGI PENELITIAN ..... 17**
3.1 Deskripsi Data ..... 17
3.1.1 Data Penelitian ..... 17
3.1.2 Definisi operasional variabel ..... 18
3.2 Tahapan Penelitian ..... 18
**BAB IV PEMBAHASAN ..... 21**
4.1 Analisis Deskriptif ..... 21
4.2 *Preprocessing Data* ..... 21
4.2.1 *Data Cleaning* ..... 22
4.2.2 *Data Transformation* ..... 22
4.3 Pembagian Data ..... 24
4.3.1 Data Training ..... 24
4.3.2 Data Testing ..... 26
4.4 Inisialisasi Bobot Awal ..... 26
4.5 Pelatihan Model *Artificial Neural Network* ..... 27
4.6 Evaluasi Kinerja Model ..... 29
4.6.1 Menghitung MSE ..... 29
4.6.2 Menghitung MAPE ..... 30
4.6.3 Pemeriksaan *Overfitting* dan *Underfitting* ..... 31
4.7 Prediksi Nilai Harga Saham BRI ..... 32
4.8 Hasil Prediksi Nilai Harga Saham BBRI.JK ..... 33
**BAB V KESIMPULAN DAN SARAN ..... 35**
5.1 Kesimpulan ..... 35
5.2 Saran ..... 35
**DAFTAR PUSTAKA ..... 36**
**LAMPIRAN ..... 38**

# DAFTAR TABEL

**Tabel 2. 1** Pemetaan Penelitian Terdahulu ..... 6
**Tabel 3.1** Data Penelitian ..... 17
**Tabel 3.2** Definisi Operasional Variabel ..... 18
**Tabel 4.1** Hasil Analisis Deskriptif ..... 21
**Tabel 4.2** Hasil Pengecekan Data Missing dan Duplikat ..... 22
**Tabel 4.3** Normalisasi Data ..... 22
**Tabel 4.4** Nilai Data Training ..... 24
**Tabel 4. 5** Nilai Data Testing ..... 26
**Tabel 4. 6** Bobot Awal Hidden Layer ..... 26
**Tabel 4.7** Bobot Awal Hidden Layer ke Output ..... 26
**Tabel 4. 8** Bobot Akhir Hidden Layer 1 ..... 27
**Tabel 4. 9** Bobot akhir Hidden Layer ke Output ..... 27
**Tabel 4.10** Perbandingan Nilai Aktual dan Prediksi dan Perhitungan MSE ..... 30
**Tabel 4.11** Pertungan MAPE ..... 30

# DAFTAR GAMBAR

**Gambar 2.1** *State of Art* ..... 5
**Gambar 2.2** Arsitektur *Single Layer* ..... 11
**Gambar 2.3** Arsitektur *Multi Layer Network* ..... 12
**Gambar 2.4** Arsitektur *Recurrent Neural Network* ..... 12
**Gambar 2.5** Kerangka Berpikir ..... 16
**Gambar 3.1** Algoritma *Artificial Neural Network* (ANN) ..... 18
**Gambar 4.1** Plot Arsitektur ANN ..... 28
**Gambar 4.2** Plot Perbandingan Data *Training* ..... 29
**Gambar 4.3** Kurva MAE ..... 31
**Gambar 4.4** Grafik Perbandingan Harga Saham Aktual vs Prediksi ..... 33

# DAFTAR LAMPIRAN

**Lampiran 1** ..... 38

# BAB I
# PENDAHULUAN

## 1.1 Latar Belakang

Pasar modal berperan penting dalam perekonomian sebagai sarana pendanaan bagi perusahaan dan investasi bagi masyarakat. Salah satu instrumen yang banyak diminati adalah saham, yaitu surat berharga yang menunjukkan kepemilikan terhadap suatu Perusahaan (Darmadji, 2011). Namun, harga saham bersifat fluktuatif dan dipengaruhi oleh berbagai faktor seperti kondisi ekonomi, kinerja perusahaan, dan sentimen pasar.

PT Bank Rakyat Indonesia (Persero) Tbk (BRI) merupakan salah satu perusahaan perbankan terbesar di Indonesia dengan basis nasabah yang luas dan kinerja yang signifikan di sektor mikro dan makro. Sebagai salah satu emiten unggulan di Bursa Efek Indonesia (BEI), pergerakan harga saham BRI sering menjadi perhatian para investor dan analis pasar. Berdasarkan data tahun 2024, harga saham BRI sempat mengalami penurunan hingga sekitar 14% dari awal tahun hingga akhir September, hal ini menunjukkan bahwa nilai saham dapat dipengaruhi oleh berbagai faktor, termasuk kinerja perusahaan dan kondisi pasar (Kurniawan, 2024).

Untuk menganalisis dan memprediksi pergerakan harga saham yang kompleks tersebut, metode statistik konvensional seperti regresi linear sering digunakan dalam analisis dan prediksi harga saham. Namun, metode ini memiliki keterbatasan karena mengasumsikan hubungan linear antara variabel input dan output serta kurang mampu menangkap pola non-linear dan dinamika kompleks pada data harga saham. Padahal, pergerakan harga saham bersifat fluktuatif, non-linear, dan dipengaruhi oleh interaksi variabel yang kompleks (Khan et al., 2006). Oleh karena itu, diperlukan metode prediksi yang mampu menangkap pola non-linear dan dinamika data historis harga saham secara lebih fleksibel, khususnya pada saham PT Bank Rakyat Indonesia (Persero) Tbk.

Dalam era digital, perkembangan teknologi machine learning dan *artificial intelligence* (AI) memungkinkan penerapan metode prediktif yang lebih canggih. Salah satu metode yang banyak digunakan adalah *Artificial Neural Network* (ANN). ANN meniru cara kerja jaringan saraf biologis manusia dalam mengenali pola dan hubungan antar data (Sebayang & Yuniarto, 2017). ANN terdiri dari beberapa lapisan, masing-masing berisi satu atau lebih neuron. Neuron-neuron ini menerima input, melakukan perhitungan, dan menghasilkan output (Aryanti & Rifai, 2023). Metode ini tidak memerlukan asumsi linearitas serta mampu menangani hubungan kompleks antar variabel secara lebih fleksibel.

Salah satu algoritma yang umum digunakan dalam ANN adalah *Backpropagation*, yang berfungsi untuk meminimalkan kesalahan prediksi dengan memperbarui bobot secara iteratif berdasarkan gradien kesalahan (Haykin, 2009). Sehingga bersifat adaptif dan mampu menyesuaikan diri terhadap perubahan pola data dari waktu ke waktu.

Dengan demikian, penggunaan Artificial Neural Network (ANN) dengan algoritma *Backpropagation* dipilih karena mampu memodelkan hubungan non-linear dan melakukan pembaruan bobot secara iteratif. Kemampuan ini memungkinkan ANN beradaptasi terhadap pola data historis yang dinamis sehingga diharapkan menghasilkan prediksi yang lebih akurat dibandingkan pendekatan regresi konvensional. Penelitian ini bertujuan untuk memprediksi harga penutupan yang telah disesuaikan (*adjusted close*) PT Bank Rakyat Indonesia (Persero) Tbk menggunakan metode *Artificial Neural Network* (ANN) dengan algoritma Backpropagation berdasarkan data historis, sehingga dapat memberikan wawasan yang bermanfaat bagi investor, analis keuangan, maupun pelaku pasar modal dalam mengambil keputusan investasi yang lebih terinformasi.

Prinsip prediksi dan perencanaan ini juga sejalan dengan nilai-nilai yang diajarkan dalam Islam, sebagaimana kisah Nabi Yusuf ‘alaihissalam dalam QS. Yusuf [12]: 47–49:

تَاْكُلُوْنَ ٤٧ مِّمَّا قَلِيْلًا اِلَّا سُنْۢبُلِهٖٓ فِيْ فَذَرُوْهُ حَصَدْتُّمْ فَمَا ۚدَاَبًا سِنِيْنَ سَبْعَ تَزْرَعُوْنَ قَالَ

Artinya: Dia (Yusuf) berkata, "Hendaknya kamu bercocok tanam tujuh tahun (berturut-turut) sebagaimana biasa; kemudian apa yang kamu tuai hendaklah kamu biarkan ditangkainya kecuali sedikit untuk kamu makan.

٤٨ تُحْصِنُوْنَ مِّمَّا قَلِيْلًا اِلَّا لَهُنَّ قَدَّمْتُمْ مَا يَّاْكُلْنَ شِدَادٌ سَبْعٌ ذٰلِكَ بَعْدِ مِنْۢ يَاْتِيْ ثُمَّ

Artinya: Kemudian setelah itu akan datang tujuh (tahun) yang sangat sulit, yang menghabiskan apa yang kamu simpan untuk menghadapinya (tahun sulit), kecuali sedikit dari apa (bibit gandum) yang kamu simpan.

٤٩ يَعْصِرُوْنَ وَفِيْهِ النَّاسُ يُغَاثُ فِيْهِ عَامٌ ذٰلِكَ بَعْدِ مِنْۢ يَاْتِيْ ثُمَّ

Artinya: Setelah itu akan datang tahun, di mana manusia diberi hujan (dengan cukup) dan pada masa itu mereka memeras (anggur)."

Ayat ini menggambarkan konsep perencanaan dan prediksi berbasis data masa lalu, sebagaimana Nabi Yusuf A.S. memprediksi kondisi ekonomi berdasarkan mimpi raja dan data masa panen sebelumnya. Ini sangat relevan dengan penelitian kami, karena model ANN juga berfungsi memprediksi kondisi ekonomi di masa depan berdasarkan data historis.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana membangun model *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* untuk memprediksi harga penutupan (*adjusted close*) saham PT Bank Rakyat Indonesia (Persero) Tbk yang telah disesuaikan?
2. Seberapa baik kinerja model ANN *Backpropagation* dalam melakukan prediksi harga saham tersebut?

## 1.3 Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Menerapkan metode *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* dalam proses prediksi harga penutupan yang telah disesuaikan (*adjusted close*) saham PT Bank Rakyat Indonesia (Persero) Tbk.
2. Mengevaluasi kinerja model ANN Backpropagation dalam memprediksi harga saham PT Bank Rakyat Indonesia (Persero) Tbk menggunakan ukuran error.

## 1.4 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Bagi peneliti, penelitian ini menjadi sarana untuk memperdalam pemahaman mengenai penerapan algoritma *Backpropagation* pada metode ANN untuk pemodelan prediktif.
2. Bagi investor dan analis pasar, hasil prediksi dapat digunakan sebagai salah satu pertimbangan dalam pengambilan keputusan investasi yang lebih rasional.
3. Bagi dunia akademik, penelitian ini dapat menjadi referensi bagi penelitian selanjutnya yang berkaitan dengan penerapan *machine learning* dalam bidang keuangan dan pasar modal.

## 1.5 Batasan Penelitian

Agar penelitian ini lebih terarah, batasan penelitian ditetapkan sebagai berikut:

1. Data yang digunakan adalah data historis harga saham harian PT Bank Rakyat Indonesia (Persero) Tbk dengan periode tahun 2020–2024.
2. Variabel target yang digunakan adalah harga penutupan yang telah disesuaikan (*adjusted close*).

3. Variabel input yang digunakan dalam penelitian ini meliputi harga pembukaan (open), harga tertinggi (high), harga terendah (low), dan volume perdagangan.
4. Variabel harga penutupan (*close*) tidak digunakan sebagai variabel input untuk menghindari terjadinya kebocoran data (*data leakage*) dalam proses pemodelan.
5. Penelitian ini tidak mempertimbangkan faktor eksternal seperti kondisi makroekonomi, berita pasar, maupun sentimen investor.

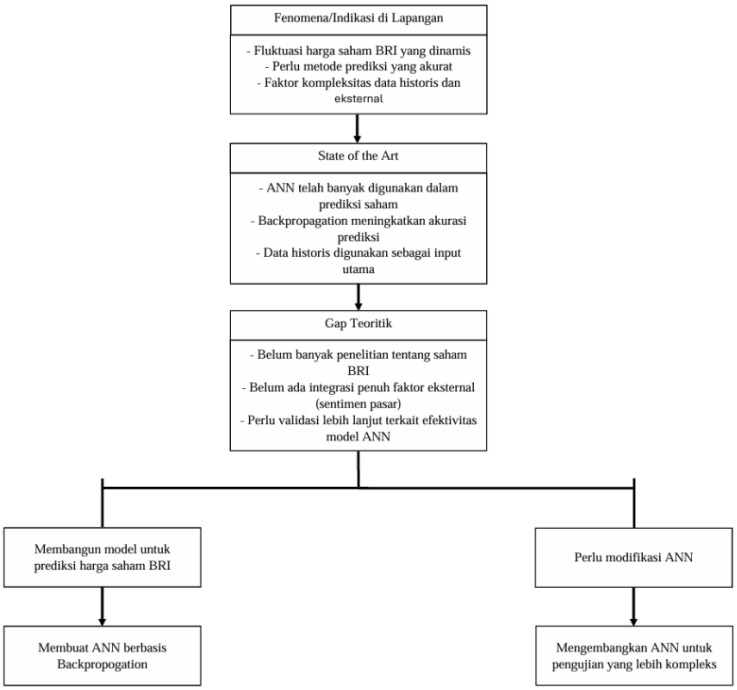
## 1.6 Sistematika Penulisan

Berikut ini sistematika penulisan yang digunakan dalam penelitian:

1. BAB I PENDAHULUAN. Bab ini membahas terkait latar belakang, rumusan masalah, tujuan penelitian, manfaat penelitian, batasan penelitian, dan sistematika penulisan.
2. BAB II TINJAUAN PUSTAKA. Bab ini membahas terkait tinjauan pustaka yang digunakan dalam penelitian. Tinjauan Pustaka yang digunakan mencakup teori yang mendukung dan berkaitan dengan topik yang dibahas.
3. BAB III METODOLOGI PENELITIAN. Bab ini membahas terkait metode yang digunakan selama penelitian dari mulai pengumpulan data sampai dengan proses yang dilakukan untuk mencapai tujuan yang telah ditetapkan.
4. BAB IV PEMBAHASAN. Bab ini berisi hasil analisis dan pembahasan.
5. BAB V KESIMPULAN DAN SARAN. Bab ini berisikan mengenai kesimpulan yang berisikan mengenai uraian singkat yang telah dilakukan dan berisikan mengenai saran dari hasil pembahasan.

# BAB II
# TINJAUAN PUSTAKA

## 2.1 Penelitian Terdahulu




**Gambar 2.1** *State of Art*

Penelitian sebelumnya telah menunjukkan keefektifan *Artificial Neural Network* (ANN) dalam berbagai bidang prediksi, termasuk memprediksi harga saham. Salah satu penelitian oleh Widhi Aryanti (2023) menunjukkan bahwa model ANN dengan arsitektur multilayer menghasilkan akurasi 96% dan RMSE sebesar 0,01128 dalam memprediksi harga saham PT. ABC. Keunggulannya terletak pada kemampuannya mengolah data kompleks tanpa bergantung pada asumsi klasik, meski memerlukan pemahaman mendalam mengenai arsitektur dan parameter jaringan (Aryanti, 2023).

Penelitian lain oleh Edwin Setiawan Nugraha & Gabrielle Jovanie Sitepu (2023), mengaplikasikan ANN dengan metode *Backpropagation* untuk memprediksi harga saham, yang menghasilkan akurasi tinggi dan nilai *Mean Squared Error* (MSE) rendah. Namun, model ini terbatas pada data historis yang tidak mempertimbangkan faktor eksternal dan diuji hanya pada satu perusahaan, sehingga membatasi generalisasi model (Innar Ridho et al., 2023).

Lebih lanjut, penelitian lainnya oleh Ihda Innar Ridho (2023) menggunakan metode *Backpropagation* dalam ANN untuk memprediksi status pinjaman, menghasilkan akurasi

tinggi, sensitivitas, dan spesifisitas yang baik. Keunggulan utama metode ini adalah kemampuannya mengenali pola tersembunyi dalam data dan meminimalkan kesalahan output. Namun, penelitian ini terbatas pada jumlah data yang digunakan, yang memengaruhi generalisasi model, serta perlu perbaikan pada sensitivitas dan skor F1 untuk mengidentifikasi pinjaman yang seharusnya diterimak (Setiawan Nugraha & Jovanie Sitepu, 2022).

Kesimpulan dari berbagai penelitian ini menunjukkan bahwa *Artificial Neural Network* (ANN) efektif untuk prediksi, seperti harga saham dan status pinjaman, berkat kemampuannya mengolah data kompleks tanpa asumsi klasik. Namun, keterbatasan terkait faktor eksternal, jumlah data, dan pengaturan parameter jaringan membatasi generalisasi dan akurasi model. Penelitian ini dapat mengisi celah tersebut dengan aplikasi ANN yang lebih spesifik dan pengembangan lebih lanjut. Peningkatan jumlah data dan optimasi parameter dapat meningkatkan kinerja model, sehingga dapat diandalkan untuk prediksi yang lebih akurat di berbagai bidang.

**Tabel 2. 1** Pemetaan Penelitian Terdahulu

| No | Penelitian | Tujuan Penelitian | Metode yang Digunakan | Hasil Penelitian | Kelebihan Kekurangan |
|---|---|---|---|---|---|
| 1 | Widhi Aryanti (2023). Penerapan *Artificial Neural Network* dengan Algoritma *Backpropagation* untuk Memprediksi Harga Saham | Menerapkan ANN dengan *Backpropagation* untuk memprediksi harga saham PT. ABC | *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* | RMSE: 0,01128, Akurasi: 96% | **Kelebihan:** Akurat tanpa asumsi klasik. **Kekurangan:** Membutuhkan pemahaman mendalam tentang ANN. |
| 2 | Edwin Setiawan Nugraha & Gabrielle Jovanie Sitepu (2023) A *Backpropagation Artificial Neural Network Approach for Loan Status Prediction* | Memprediksi status pinjaman, mengurangi risiko kredit, dan meningkatkan pemahaman tentang *Backpropagation* | *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* | Akurasi dalam prediksi status pinjaman | **Kelebihan:** Meningkatkan penilaian kelayakan calon debitur. **Kekurangan:** Bergantung pada data historis yang terbatas. |
| 3 | Ihda Innar Ridho (2023) Penerapan *Artificial Neural Network* dengan Metode *Backpropagation* Dalam Memprediksi Harga Saham (Kasus:PT. Bank BCA, Tbk)) | Mengembangkan model prediksi harga saham dengan ANN dan *Backpropagation* | *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* | Akurasi tinggi, MSE rendah | **Kelebihan:** Efektif memprediksi harga saham. **Kekurangan:** Bergantung pada data historis, hanya diuji pada satu perusahaan. |

Berdasarkan penelitian-penelitian terdahulu tersebut, dapat disimpulkan bahwa metode *Artificial Neural Network* dengan algoritma *Backpropagation* efektif digunakan dalam memprediksi data yang bersifat non-linear, termasuk harga saham. Namun, sebagian besar penelitian masih berfokus pada penggunaan harga penutupan (*close*) tanpa mempertimbangkan harga penutupan yang telah disesuaikan (*adjusted close*), serta menggunakan data dengan frekuensi harian. Oleh karena itu, penelitian ini berfokus pada prediksi harga *adjusted close* saham PT Bank Rakyat Indonesia (Persero) Tbk menggunakan data bulanan, sehingga diharapkan dapat memberikan sudut pandang berbeda dan hasil prediksi yang lebih stabil.

## 2.2 Harga Saham

Saham adalah surat berharga yang mencerminkan kepemilikan atas bagian tertentu dari perusahaan, memberikan hak kepada pemegangnya untuk menerima dividen dan ikut serta dalam pengambilan keputusan perusahaan melalui hak suara di Rapat Umum Pemegang Saham (RUPS) (Husnan, 2015). Saham juga dapat diperdagangkan di pasar modal, dan harga saham tersebut sangat dipengaruhi oleh berbagai faktor ekonomi dan kinerja perusahaan(Kasmir, 2016). Harga saham adalah nilai yang diperdagangkan di pasar saham, yang mencerminkan seberapa besar nilai pasar yang diberikan oleh investor terhadap suatu perusahaan. Fluktuasi harga saham dipengaruhi oleh faktor internal perusahaan dan kondisi eksternal seperti ekonomi makro dan sentimen pasar (Ang, 2020). Selain itu, analisis teknikal dan fundamental digunakan untuk memprediksi pergerakan harga saham di masa depan (Effendi, 2017). Analisis teknikal berfokus pada data historis harga saham dan volume perdagangan untuk mengidentifikasi pola atau tren yang dapat memprediksi pergerakan harga saham di masa depan. Sedangkan analisis fundamental melihat kinerja dan kondisi keuangan perusahaan, seperti pendapatan, laba, serta rasio keuangan, untuk memperkirakan nilai intrinsik saham(Fama & French, 2015).

## 2.3 Harga Penutupan yang Disesuaikan (*Adjusted Close*)

*Adjusted Close* merupakan harga penutupan saham yang telah disesuaikan dengan aksi korporasi seperti pembagian dividen, stock split, dan reverse stock split. Penggunaan *adjusted close* dalam analisis dan prediksi harga saham dianggap lebih representatif karena mencerminkan nilai historis saham yang sesungguhnya serta menghindari distorsi akibat perubahan struktural harga. Oleh karena itu, dalam penelitian ini *adjusted close* digunakan sebagai variabel target (*output*) dalam pemodelan ANN.

## 2.4 Data *Preprocessing*

*Data preprocessing* merupakan tahap awal dalam proses analisis data yang bertujuan untuk menyiapkan data agar siap diolah dan dianalisis. Tahap ini penting dilakukan karena data mentah sering kali mengandung ketidaksempurnaan seperti nilai yang hilang, duplikasi, atau perbedaan skala antar variabel. Melalui proses preprocessing, kualitas data dapat ditingkatkan sehingga hasil analisis menjadi lebih akurat dan reliabel.

### 2.4.1 Data *Cleaning*

Data *cleaning* merupakan proses pembersihan data untuk memastikan bahwa data yang digunakan dalam analisis bebas dari kesalahan dan memiliki kualitas yang baik. Tujuan utama tahap ini adalah untuk meningkatkan keakuratan hasil analisis dengan mengidentifikasi dan memperbaiki masalah dalam data.

Pada penelitian ini, proses data cleaning dilakukan dengan dua langkah utama, yaitu:

1. Pengecekan data hilang (*missing values*), untuk memastikan tidak ada observasi yang tidak lengkap yang dapat memengaruhi hasil analisis. Jika ditemukan, nilai yang hilang akan dipertimbangkan untuk dihapus atau diisi menggunakan metode yang sesuai.
2. Pengecekan data duplikat (*duplicate data*), untuk memastikan bahwa setiap observasi bersifat unik. Data yang terdeteksi ganda akan dihapus agar tidak menimbulkan bias pada hasil analisis.

### 2.4.2 Normalisasi Data

Normalisasi data merupakan proses transformasi nilai data ke dalam skala tertentu agar setiap variabel memiliki kontribusi yang seimbang dalam analisis statistik atau pemodelan. Tujuan utama normalisasi adalah menghilangkan perbedaan skala antar variabel sehingga tidak ada variabel yang mendominasi hasil analisis hanya karena memiliki rentang nilai yang lebih besar. Normalisasi data pada penelitian ini menggunakan metode minmax dengan rumus sebagai berikut (Jiawei & Kamber, 2006):

$$X' = \frac{(X - X_{Min})}{(X_{Max} - X_{Min})} \tag{2.1}$$

## 2.5 Analisis Deskriptif

Statistik deskriptif digunakan untuk memberikan gambaran umum mengenai karakteristik data sebelum dilakukan analisis lebih lanjut. Analisis ini bertujuan untuk

mengetahui sebaran, kecenderungan, serta variasi data dari masing-masing indikator kesejahteraan masyarakat sebelum dilakukan analisis lanjutan.

Ukuran pemusatan data meliputi nilai rata-rata (*mean*) dan median ($Q_2$), sedangkan ukuran penyebaran mencakup simpangan baku (*standard deviation*), nilai minimum dan maksimum, serta kuartil pertama (Q1) dan kuartil ketiga (Q3).

Nilai rata-rata (*mean*) dapat dihitung dengan rumus:

$$\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n} \tag{2.2}$$

Keterangan:

$\bar{X}$ = Nilai Rata-rata (*Mean*)

$X_i$ = Data ke-i

$n$ = Jumlah Data

Simpangan baku (*standard deviation*) menggambarkan tingkat penyebaran data terhadap rata-ratanya dan dihitung dengan rumus:

$$s = \sqrt{\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}} \tag{2.3}$$

Keterangan:

s = Simpangan Baku

$X_i$ = Data ke-i

$\bar{X}$ = Nilai Rata-rata (*Mean*)

$n$ = Jumlah Data

Untuk menentukan nilai kuartil ($Q_1, Q_2, Q_3$) digunakan rumus posisi data berikut:

$$Q_k = \frac{k(n+1)}{4} \; dengan \; k = 1, 2, 3 \tag{2.4}$$

Keterangan:

$Q_k$ = Kuartil ke-k

$k$ = $1, 2, 3$

$n$ = Jumlah Data

## 2.6 *Artificial Neural Network*

*Artificial Neural Network* (ANN) adalah sistem komputasi yang meniru cara kerja otak manusia dalam mengenali pola. Meskipun diperkenalkan pada 1950-an, perkembangan pesat terjadi pada 1980-an dengan penemuan algoritma *Backpropagation* yang memungkinkan jaringan belajar secara efisien. ANN banyak digunakan dalam aplikasi seperti pengenalan pola dan prediksi harga saham(Goodfellow et al., 2016) (LeCun & Hinton, 2015). ANN memanfaatkan struktur berlapis untuk memetakan hubungan kompleks dalam data (*Neural Networks and Learning Machines (3rd Ed.)*, 2016).

Secara umum, Artificial Neural Network (ANN) tersusun atas beberapa lapisan (layer), yaitu input layer, hidden layer, dan output layer (Haykin, 2009). Input layer berfungsi menerima data masukan yang merepresentasikan variabel-variabel penelitian. Hidden layer merupakan lapisan tersembunyi yang berperan penting dalam memproses dan mempelajari pola hubungan yang kompleks dan non-linear di dalam data melalui pembobotan dan fungsi aktivasi (Aryanti & Rifai, 2023). Semakin banyak neuron atau hidden layer yang digunakan, semakin tinggi kemampuan jaringan dalam mengenali pola yang rumit (Haykin, 2009). Sementara itu, output layer berfungsi menghasilkan keluaran berupa nilai prediksi berdasarkan proses pembelajaran yang telah dilakukan pada lapisan sebelumnya

Seperti neuron dalam biologi, ANN bersifat "*fault tolerant*", mampu mengenali sinyal input yang sedikit berbeda dan tetap berfungsi meskipun beberapa neuron rusak (Windarto, 2017b). ANN memiliki karakteristik unik, seperti kemampuan untuk belajar dan menyelesaikan masalah kompleks yang tidak bisa dimodelkan dengan sistem linier (Windarto, 2017a). Namun, ANN juga memiliki kelemahan, seperti kesulitan menentukan jumlah neuron dan lapisan yang optimal, serta perlambatan dalam pelatihan (Das et al., 2018).

ANN memiliki tiga arsitektur utama (Hermawan, 2006) (Lesnussa, 2015):

1. Jaringan Lapisan Tunggal (*Single Layer Network*), dengan satu lapisan input dan output tanpa lapisan tersembunyi.
2. Jaringan Banyak Lapisan (*Multilayer Network*), dengan tiga lapisan: input, tersembunyi, dan output, yang dapat menangani masalah lebih kompleks meski memerlukan waktu pelatihan lebih lama.
3. Jaringan Lapisan Kompetitif (*Competitive Layer*), di mana neuron bersaing untuk menjadi aktif, seperti pada algoritma LVQ.

## 2.7 Struktur Jaringan *Artificial Neural Network*

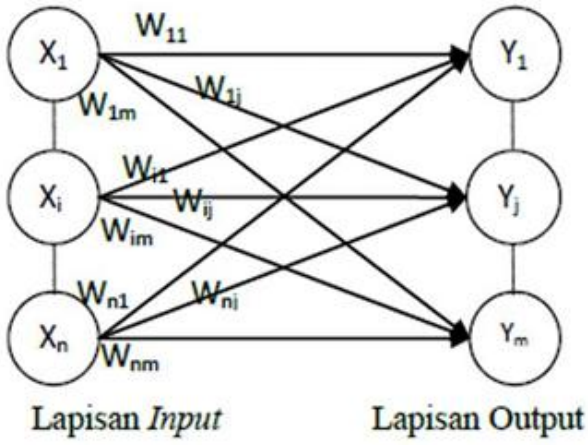
*Artificial Neural Network* (ANN) tersusun atas beberapa lapisan utama, yaitu *input layer, hidden layer,* dan *output layer*. Input layer berfungsi untuk menerima data masukan berupa variabel independen, dalam penelitian ini meliputi harga pembukaan (*open*), harga tertinggi (*high*), harga terendah (*low*), dan volume perdagangan. *Hidden layer* berperan dalam memproses informasi melalui pembobotan dan fungsi aktivasi untuk menangkap pola non-linear pada data. *Output layer* menghasilkan keluaran akhir berupa nilai prediksi, yaitu harga penutupan yang telah disesuaikan (*adjusted close*).

## 2.8 Arsitektur Artificial Neural Network

Menurut (makosso et al., 2025), arsitektur ANN secara umum dapat dibedakan menjadi tiga jenis utama, yaitu *Single Layer Network*, *Multi Layer Network*, dan *Recurrent Network*. Penjelasan masing-masing arsitektur disajikan sebagai berikut:

1. *Single Layer*

   *Single Layer Network* merupakan arsitektur ANN paling sederhana. Jaringan ini hanya terdiri dari satu lapisan bobot, yaitu lapisan *output*, tanpa adanya *hidden layer*. *Input* langsung dihubungkan ke neuron *output* melalui bobot tertentu. Arsitektur ini umumnya digunakan untuk permasalahan yang bersifat linear dan relatif sederhana, seperti klasifikasi dasar atau regresi linear. Keterbatasan utama *Single Layer Network* adalah ketidakmampuannya dalam memodelkan hubungan nonlinier yang kompleks.

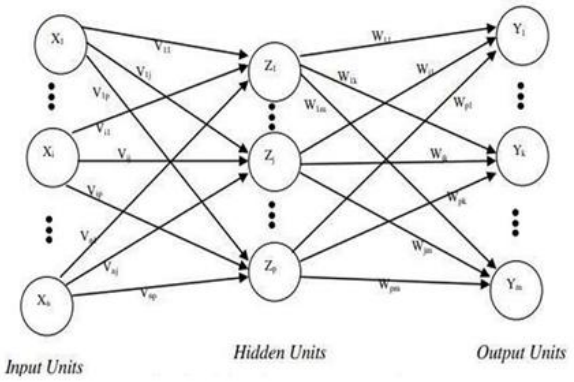



**Gambar 2.2** Arsitektur *Single Layer*

2. *Multi Layer Network*

   *Multi Layer Network* atau *Multilayer Perceptron* (MLP) merupakan pengembangan dari *Single Layer Network* dengan menambahkan satu atau lebih *hidden layer* di

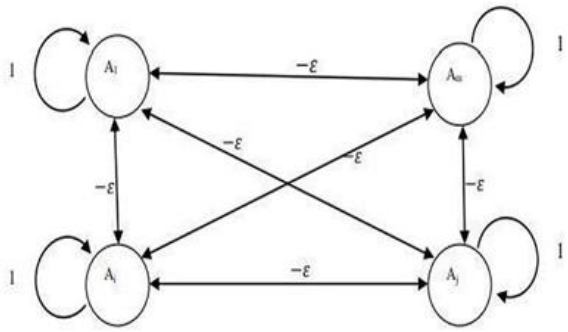
antara lapisan input dan *output. Hidden layer* memungkinkan jaringan untuk mempelajari pola nonlinier yang lebih kompleks melalui proses transformasi bertahap. Arsitektur ini paling banyak digunakan dalam praktik, terutama untuk masalah klasifikasi dan prediksi dengan kompleksitas tinggi. Proses pembelajaran pada *Multi Layer Network* umumnya dilakukan menggunakan algoritma *backpropagation* untuk meminimalkan kesalahan prediksi.




**Gambar 2.3** Arsitektur *Multi Layer Network*

3. *Recurrent Network*

*Recurrent Neural Network* (RNN) merupakan arsitektur ANN yang memiliki umpan balik (*feedback*), sehingga *output* pada waktu tertentu dapat memengaruhi proses komputasi pada waktu berikutnya. Hal ini membuat RNN sangat cocok digunakan untuk data yang bersifat sekuensial atau runtun waktu, seperti data time series, teks, dan sinyal. Keunikan RNN terletak pada kemampuannya menyimpan informasi masa lalu dalam bentuk *state*, sehingga jaringan dapat mengenali pola yang bergantung pada urutan waktu. Namun, RNN klasik memiliki keterbatasan dalam menangani ketergantungan jangka panjang, yang kemudian dikembangkan lebih lanjut menjadi varian seperti LSTM dan GRU.



**Gambar 2.4** Arsitektur *Recurrent Neural Network*

## 2.9 Algoritma *Backpropagation*

*Backpropagation* adalah metode dalam jaringan saraf tiruan berlapis banyak yang efektif untuk prediksi. Algoritma ini menggeneralisasi aturan delta (*Widrow-Hoff*) dengan menggunakan penurunan gradien untuk meminimalkan kesalahan kuadrat pada output. Proses pelatihan melibatkan dua tahap utama yaitu propagasi maju dan pembaruan bobot (Setti & Wanto, 2019). Metode ini meminimalkan kesalahan pada output dengan melatih jaringan untuk mengenali pola selama pelatihan dan memberikan respon yang tepat terhadap pola serupa (A. Wanto, 2018).

Pelatihan *Backpropagation* terdiri dari tiga fase (Santoso & Hansun, 2019):

1. *Feedforward* : Menghitung pola input dan menghasilkan output.
2. *Backpropagation* : Menghitung kesalahan dan mempropagasikannya kembali.
3. Modifikasi Bobot : Menyesuaikan bobot untuk meminimalkan kesalahan.

### 2.9.1 Proses ANN *Backpropagation*

Pada penelitian ini digunakan fungsi aktivasi sigmoid biner. Rumus-rumus yang digunakan dalam proses pembelajaran ANN Backpropagation mengacu pada (Aris Puji Widodo et al., 2017):

1. Aktivasi Kesalahan pada *Output Layer*

$$\delta_l = (t_l - y_l) f'(y_{net\,l}) \tag{2.5}$$

2. Perubahan Bobot pada *Output Layer*

$$\Delta w_{jk} = \alpha \delta_l z_j \tag{2.6}$$

3. Menghitung koreksi bias

$$\Delta w_{0k} = \alpha \delta_l \tag{2.7}$$

4. Delta Input ke *Hidden Layer*

$$\delta_{net_l} = \sum_{l=1}^{k} \delta_l \, w_{jk} \tag{2.8}$$

5. Aktivasi Kesalahan pada *Hidden layer*

$$\delta_l = \delta_{net_l} f'\left(Z_{net_j}\right) = \delta_{net_l} Z_j (1 - Z_j) \tag{2.9}$$

6. Koreksi bobot

$$\Delta v_{ij} = \alpha \delta_j Z_i \tag{2.10}$$

7. Koreksi Bias pada *Hidden Layer*

$$\Delta v_{0j} = \alpha \delta_j \tag{2.11}$$

### 2.9.2 Fungsi Aktivasi

Fungsi aktivasi berperan dalam mengatur pemrosesan informasi pada setiap neuron dengan mentransformasi hasil penjumlahan bobot dan input menjadi nilai keluaran tertentu. Pada penelitian ini, fungsi aktivasi Sigmoid digunakan pada *hidden layer* untuk menangkap hubungan non-linear antar variabel input. Fungsi Sigmoid dirumuskan sebagai berikut (Aris Puji Widodo et al., 2017):

$$y = f(x) = \frac{1}{1 + exp^{-x}} \tag{2.12}$$

Sementara itu, pada output layer digunakan fungsi aktivasi linear karena variabel target yang diprediksi berupa data kontinu, yaitu harga penutupan yang telah disesuaikan (*adjusted close*).

### 2.9.3 Pengujian Akurasi dan *Error*

Pengujian memastikan kesesuaian input, proses, dan output.i *Mean Square Error* (MSE) dan *Mean Absolute Percentage Error* (MAPE) rendah mendekati nol menunjukkan prediksi akurat. Rumusnya (Aris Puji Widodo et al., 2017):

$$MSE = \sum_{i=1}^{n} \frac{(y_l - t_l)^2}{n} \tag{2.13}$$

$$MAPE = \frac{\sum_{i=1}^{n} \frac{|xt - yt|}{yt}}{n} 100\% \tag{2.14}$$

Akurasi mencerminkan rendahnya tingkat kesalahan pengukuran. Semakin tinggi akurasi, semakin kecil kesalahan. Rumus akurasi (Aris Puji Widodo et al., 2017):

$$\text{Akurasi} = 100\% - MAPE \tag{2.15}$$

## 2.10 Prediksi/Peramalan

Prediksi adalah proses perkiraan mengenai kebutuhan yang akan terjadi di masa depan, mencakup aspek waktu, lokasi, kuantitas, dan kualitas untuk memenuhi permintaan barang atau jasa (Monika et al., 2019). Dalam konteks penelitian ini, prediksi digunakan untuk memperkirakan nilai harga saham pada periode mendatang berdasarkan pola historis data yang tersedia, sehingga hasil prediksi dapat dijadikan sebagai dasar dalam pengambilan keputusan.

## 2.11 *Overfitting* dan *Underfitting*

Dalam pemodelan machine learning, khususnya pada *Artificial Neural Network* (ANN), permasalahan yang sering muncul adalah underfitting dan *overfitting*. Underfitting

terjadi ketika model terlalu sederhana sehingga tidak mampu menangkap pola utama yang terdapat dalam data. Kondisi ini ditandai dengan nilai *error* yang relatif tinggi baik pada *data training* maupun *data testing*, yang menunjukkan bahwa model gagal merepresentasikan hubungan antara variabel input dan output secara memadai (Czajkowski & Kretowski, 2019). *Underfitting* umumnya disebabkan oleh keterbatasan kompleksitas model, jumlah *neuron* yang terlalu sedikit, atau proses pelatihan yang belum optimal.

Sebaliknya, *overfitting* terjadi ketika model terlalu kompleks dan menyesuaikan diri secara berlebihan terhadap *data training*, termasuk menangkap *noise* atau fluktuasi acak yang tidak merepresentasikan pola sebenarnya. Akibatnya, model menghasilkan kinerja yang sangat baik pada *data training* tetapi memiliki performa yang buruk pada *data testing* (Peng & Nagata, 2020). *Overfitting* sering disebabkan oleh penggunaan jumlah parameter yang terlalu banyak, seperti jumlah *hidden layer* atau neuron yang berlebihan, terutama ketika jumlah data yang tersedia relatif terbatas. Oleh karena itu, pemilihan arsitektur ANN yang tepat menjadi penting untuk menyeimbangkan kompleksitas model agar dapat menghindari underfitting maupun overfitting serta menghasilkan kemampuan generalisasi yang baik.

*Mean Absolute Error* (MAE) merupakan salah satu ukuran kinerja yang umum digunakan dalam evaluasi model regresi, termasuk pada pemodelan *Artificial Neural Network* (ANN). MAE mengukur rata-rata nilai absolut selisih antara nilai aktual dan nilai prediksi, semakin rendah nilai MAE maka semakin baik modelnya dalam melakukan prediksi, MAE dihitung dengan persamaan berikut:

$$MAE = \frac{1}{n}\sum_{i=1}^{n} |y_i - F(\hat{y}_i)| \tag{2.16}$$

Keterangan:

n = total observasi

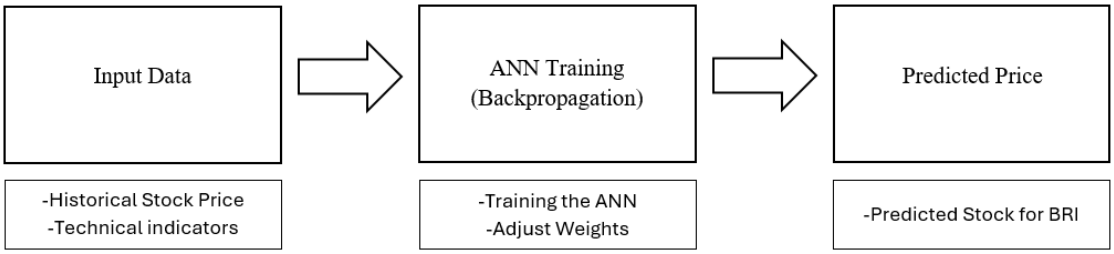
$y_i$ = Nilai target aktual

$F(\hat{y}_i)$ = Nilai target prediksi dari model untuk observasi ke-$i$.

## 2.12 Kerangka Berpikir

Kerangka berpikir pada penelitian ini bertujuan untuk menggambarkan alur proses prediksi harga saham PT Bank Rakyat Indonesia (Persero) Tbk menggunakan metode *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation*. Kerangka ini

mengilustrasikan langkah-langkah utama mulai dari pemrosesan data input hingga hasil prediksi. Proses tersebut melibatkan pengolahan data historis harga saham dan indikator teknikal, pelatihan model ANN, dan evaluasi hasil prediksi. Berikut adalah representasi kerangka berpikir dalam bentuk bagan:




**Gambar 2.5** Kerangka Berpikir

# BAB III
# METODOLOGI PENELITIAN

## 3.1 Deskripsi Data

### 3.1.1 Data Penelitian

Dataset berupa data sekunder yang berisi harga saham PT Bank Rakyat Indonesia (BBRI.JK) khususnya harga penutupan yang telah disesuaikan (*adjusted close*) dari sumber *Yahoo Finance* untuk periode Januari 2020 hingga Desember 2024. Dataset tersebut kemudian dilakukan proses pemilihan data untuk mengubah data harian menjadi data bulanan. Proses ini dilakukan dengan cara mengambil data pada hari perdagangan terakhir setiap bulan. Pendekatan ini dipilih karena harga penutupan pada hari terakhir bulan tersebut dianggap paling merepresentasikan kondisi pasar pada akhir periode tersebut.

Dari hasil pemilihan ini, diperoleh 60 observasi (5 tahun × 12 bulan), di mana setiap observasi mewakili satu bulan pengamatan. Variabel yang digunakan pada tahap analisis selanjutnya meliputi *Open, High, Low*, dan *Adjusted Close* sesuai dengan kebutuhan pemodelan ANN. Variabel *Adjusted Close* dipilih sebagai variabel target (*output*) dalam pemodelan karena telah memperhitungkan faktor penyesuaian seperti pembagian dividen dan stock split, sehingga lebih stabil dan merepresentasikan nilai wajar saham secara lebih akurat.

Pada tahap pemodelan, data dianalisis menggunakan *Artificial Neural Network* (ANN) dengan arsitektur *Multilayer*, yang terdiri atas satu *hidden layer* dengan tiga neuron. Variabel *Open, High, dan Low* digunakan sebagai variabel input, sedangkan *Adjusted Close* sebagai variabel *output*. Pemilihan satu *hidden layer* dilakukan untuk menjaga keseimbangan antara kemampuan model dalam menangkap pola nonlinier dan risiko *overfitting*, sementara jumlah tiga neuron dipilih untuk menyesuaikan kompleksitas model dengan jumlah observasi yang relatif terbatas.

**Tabel 3.1** Data Penelitian

| ***Date*** | ***Open*** | ***High*** | ***Low*** | ***Adjusted Close*** |
|---|---|---|---|---|
| 2020-01-31 | 4154 | 4164 | 4054 | 2994 |
| 2020-02-28 | 3627 | 3809 | 3554 | 2923 |
| 2020-03-31 | 2818 | 2909 | 2700 | 2107 |
| … | … | … | … | … |
| 2024-11-29 | 4280 | 4300 | 4250 | 3887,80542 |
| 2024-12-30 | 4080 | 4120 | 4070 | 3856,244141 |

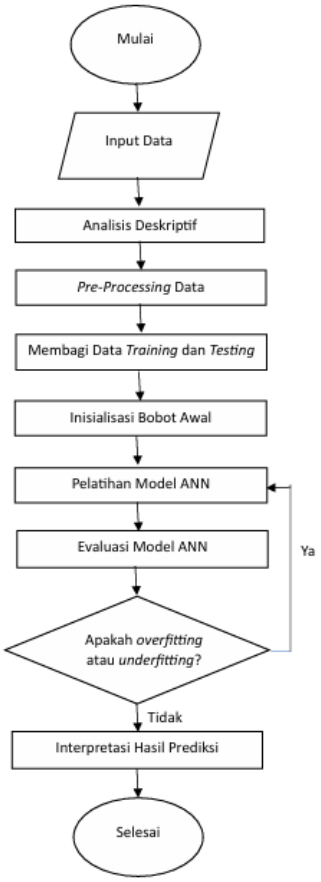
### 3.1.2 Definisi operasional variabel

Definisi operasional variabel digunakan untuk menjelaskan variabel yang digunakan dalam penelitian secara terukur dan jelas, sehingga tidak menimbulkan perbedaan penafsiran. Variabel dalam penelitian ini terdiri dari variabel input dan variabel output yang digunakan dalam pemodelan *Artificial Neural Network* (ANN).

**Tabel 3.2** Definisi Operasional Variabel

| Variabel | Definisi Operaional | Jenis Data | Skala Data |
|---|---|---|---|
| *Open* | Harga pembukaan saham PT Bank Rakyat Indonesia (Persero) Tbk pada setiap periode pengamatan | Numerik | Rasio |
| *High* | Harga tertinggi saham PT Bank Rakyat Indonesia (Persero) Tbk pada setiap periode pengamatan | Numerik | Rasio |
| *Low* | Harga terendah saham PT Bank Rakyat Indonesia (Persero) Tbk pada setiap periode pengamatan | Numerik | Rasio |
| *Adjusted Close* | harga penutupan saham yang telah disesuaikann pada hari perdagangan terakhir bulan tersebut | Numerik | Rasio |

## 3.2 Tahapan Penelitian




**Gambar 3.1** Diagram Alur *Artificial Neural Network (ANN)*

Berikut tahapan analisis Algoritma *Artificial Neural Network* (ANN):

1. Input Data

   Tahap awal penelitian dimulai dengan menginput data yang digunakan dalam analisis. Data yang diambil dapat berupa data historis harga saham atau faktor-faktor eksternal yang berpengaruh terhadap pergerakan harga saham.

2. Analisis Deskriptif

   Analisis deskriptif dilakukan pada tahap awal penelitian untuk menggambarkan karakteristik data harga saham yang digunakan. Analisis ini mencakup perhitungan ukuran statistik deskriptif seperti nilai minimum, maksimum, rata-rata (mean), median, dan standar deviasi guna mengetahui pola, sebaran, serta kecenderungan data.

3. *Pre-procesing* Data

   Pada tahap ini dilakukan pemilihan variabel yang relevan dengan tujuan penelitian. Setelah data dipilih, dilakukan proses pembersihan data untuk memastikan data bebas dari kesalahan, seperti nilai yang hilang (*missing values*) atau data yang duplikat. Data yang bersih akan menghasilkan analisis yang lebih akurat dan valid. Setelah itu dilakukan normalisasi untuk menyeragamkan skala antar variabel agar setiap variabel memiliki kontribusi yang seimbang dalam model. Normalisasi membantu mempercepat proses pelatihan model dan meningkatkan akurasi hasil prediksi. Dengan rumus pada persamaan 2.1.

4. Tahap *Split* Data

   Data yang telah dinormalisasi kemudian dibagi menjadi dua bagian, yaitu data latih (*training data*) dan data uji (*testing data*). Data latih digunakan untuk membangun model, sedangkan data uji digunakan untuk mengukur performa model. Dengan perbandingan 80:20.

5. Inisialisasi Bobot Awal

   Inisialisasi bobot awal merupakan tahap awal sebelum proses pelatihan Artificial Neural Network (ANN) menggunakan algoritma *Backpropagation*. Pada tahap ini, setiap hubungan antar neuron pada lapisan input, hidden layer, dan output diberikan nilai bobot serta bias awal yang diinisialisasi secara acak. Pemberian bobot awal secara acak bertujuan untuk menghindari kondisi simetri pada jaringan dan memungkinkan setiap neuron mempelajari pola yang berbeda selama proses pembelajaran. Bobot awal ini digunakan sebagai titik awal dalam proses *feedforward* untuk menghasilkan keluaran awal jaringan, yang selanjutnya diperbarui secara

iteratif melalui proses *backpropagation* hingga diperoleh bobot akhir yang optimal dengan nilai *error* minimum.

6. Pelatihan Model ANN

   Pada tahap ini dilakukan proses pelatihan model untuk memprediksi harga saham menggunakan metode *Artificial Neural Network* (ANN) dengan algoritma Backpropagation. Model dilatih menggunakan data latih yang telah dipersiapkan sebelumnya melalui proses *feedforward* dan *backpropagation* untuk meminimalkan nilai *error*. Proses pelatihan ini mengacu pada persamaan (2.5) hingga (2.12) yang digunakan dalam perhitungan keluaran jaringan dan pembaruan bobot secara iteratif. Fungsi aktivasi sigmoid digunakan pada neuron di *hidden layer* dan *output layer* untuk mentransformasikan kombinasi linier dari input menjadi keluaran nonlinier. Penggunaan fungsi aktivasi sigmoid memungkinkan model ANN untuk menangkap hubungan nonlinier antara variabel input dan output serta membantu proses pembelajaran jaringan agar lebih stabil. Fungsi aktivasi sigmoid yang digunakan mengacu pada persamaan (2.12).

7. Evaluasi Model

   Setelah model terbentuk, dilakukan evaluasi untuk mengukur tingkat akurasi dan kesalahan (*error*). Tahap ini bertujuan untuk mengevaluasi seberapa baik model mampu memprediksi harga saham dibandingkan dengan data aktual. Dengan rumus pada persamaan (2.13),(2.14) dan (2.15).

8. Melakukan pemeriksaan *overfitting* dan *underfitting*.

   Analisis underfitting dan overfitting dilakukan untuk mengevaluasi kemampuan generalisasi model Artificial Neural Network (ANN) yang dibangun. Pada tahap ini, evaluasi dilakukan dengan membandingkan nilai *Mean Absolute Error* (MAE) antara *data training* dan *data testing*, MAE dihitung menggunaan persamaan (2.16).

9. Prediksi Nilai Harga Saham

   Berdasarkan hasil evaluasi, model terbaik kemudian dibentuk dan disimpan sebagai model akhir yang akan digunakan untuk prediksi.

10. *Output*

    Tahap terakhir adalah menampilkan hasil prediksi harga saham yang diperoleh dari model. *Output* ini menjadi dasar dalam melakukan interpretasi dan pengambilan keputusan terkait pergerakan harga saham.

# BAB IV
# PEMBAHASAN

## 4.1 Analisis Deskriptif

Sebelum dilakukan pemodelan ANN lebih lanjut, data saham dianalisis secara deskriptif untuk mengetahui pola dan karakteristik variabel yang digunakan. Melalui analisis ini, dapat dilihat bagaimana fluktuasi harga saham dari tahun 2020 hingga 2024 serta seberapa besar variasi yang terjadi. Hasil analisis ini menjadi dasar untuk menentukan perlakuan data pada tahap *preprocessing*.

**Tabel 4.1** Hasil Analisis Deskriptif

| Statistik | Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|---|
| Mean | 4.362,54 | 4.419,30 | 4.303,77 | 278.607.146,52 | 3.630,63 |
| Median | 4.410,00 | 4.450,00 | 4.335,00 | 226.547.900,00 | 3.725,58 |
| Standar Deviasi | 886,50 | 877,38 | 888,54 | 182.727.336,27 | 909,49 |
| Minimum | 2.381,78 | 2.490,87 | 2.372,69 | 78.498.500,00 | 1.904,40 |
| Range | 3.768,22 | 3.709,13 | 3.752,31 | 881.386.109,00 | 3.630,00 |
| Maksimum | 6.150,00 | 6.200,00 | 6.125,00 | 959.884.609,00 | 5.534,41 |
| Kuartil 1 (Q1) | 3.800,00 | 3.886,00 | 3.747,00 | 157.740.275,00 | 2.921,00 |
| Kuartil 3 (Q3) | 4.870,00 | 4.985,00 | 4.862,00 | 318.274.828,00 | 4.328,00 |

Berdasarkan hasil analisis deskriptif terhadap 60 data bulanan, terlihat karakteristik data yang cenderung simetris karena nilai Mean dan Median yang berdekatan, namun memiliki rentang fluktuasi yang lebar pada variabel harga serta lonjakan ekstrem pada variabel Volume. Keberagaman skala dan varians yang tinggi antar variabel ini menjelaskan alasan di balik perlunya tahap normalisasi data, guna memastikan model ANN dapat memproses sebaran data tersebut secara stabil tanpa terdistorsi oleh perbedaan nilai absolut yang mencolok.

## 4.2 *Preprocessing Data*

Pada tahap *Preprocessing* terdapat beberapa langkah yang dilakukan untuk mempersiapkan data mentah menjadi data yang siap digunakan untuk proses data *mining*.

### 4.2.1 *Data Cleaning*

Pada tahap *data cleaning*, dilakukan proses pemeriksaan terhadap data untuk memastikan bahwa data yang akan digunakan dalam pemodelan berada dalam kondisi bersih dan layak olah. Pemeriksaan dilakukan untuk mendeteksi adanya *missing value*, duplikasi data, serta inkonsistensi pada setiap variabel.

Berdasarkan hasil pengecekan, tidak ditemukan adanya nilai yang hilang (*missing value*) maupun data ganda (*duplicate records*), sehingga seluruh observasi dapat digunakan pada tahap analisis berikutnya.

**Tabel 4.2** Hasil Pengecekan Data Missing dan Duplikat

| Jenis Pengecekan | Hasil *Output* | Keterangan |
|---|---|---|
| Data *Missing* | 0 | Tidak terdapat data yang hilang |
| Data Duplikat | FALSE | Tidak terdapat data yang duplikat |

### 4.2.2 *Data Transformation*

Tahap *data transformation* dilakukan untuk menyeragamkan skala data agar seluruh variabel memiliki rentang nilai yang sama dan siap digunakan pada proses pelatihan model *Artificial Neural Network (ANN)*. Transformasi dilakukan menggunakan metode normalisasi Min–Max, sebagaimana dijelaskan pada Bab III.

Proses ini diterapkan pada seluruh variabel input (*Open, High, Low, Adjusted Close*) dan variabel target (*Adjusted Close*), sehingga setiap nilai berada dalam rentang antara 0 dan 1

**Tabel 4.3** Normalisasi Data

| Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|
| 0,47043303 | 0,45096739 | 0,44820055 | 0,08199035 | 0,30027769 |
| 0,33050934 | 0,35538192 | 0,31495177 | 0,15051759 | 0,28057084 |
| 0,11579887 | 0,1127419 | 0,08721741 | 0,30407076 | 0,05572982 |
| 0 | 0 | 0 | 0,45018976 | 0 |
| 0,01929983 | 0,05146916 | 0,02180439 | 1 | 0,04227781 |
| 0,10856145 | 0,09068368 | 0,10175363 | 0,07819526 | 0,05765147 |
| 0,12303636 | 0,10538911 | 0,12113529 | 0,00888324 | 0,08263384 |
| 0,26054756 | 0,24509095 | 0,2156208 | 0,24297319 | 0,14989396 |
| 0,10614895 | 0,08333096 | 0,09448552 | 0,12040575 | 0,05957319 |
| 0,17369837 | 0,16176006 | 0,17443482 | 0,13971367 | 0,12106816 |
| 0,39323377 | 0,37744008 | 0,33433337 | 0,47106399 | 0,26135361 |
| 0,37875892 | 0,36028371 | 0,36825131 | 0,02328854 | 0,27672734 |
| 0,47043303 | 0,45832017 | 0,3803648 | 0,26064441 | 0,27864905 |

| Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|
| 0,5090327 | 0,4926329 | 0,50634547 | 0,09450785 | 0,38050012 |
| 0,44148335 | 0,42645831 | 0,39974646 | 0,27756418 | 0,32092694 |
| 0,36910901 | 0,3480292 | 0,34886965 | 0,20308845 | 0,27243692 |
| 0,36428408 | 0,37744008 | 0,36340586 | 0,28142055 | 0,31376622 |
| 0,30879708 | 0,3014619 | 0,31010632 | 0,05177692 | 0,25078811 |
| 0,29190974 | 0,26714917 | 0,26649762 | 0,03986297 | 0,20552263 |
| 0,31844699 | 0,29656011 | 0,30526094 | 0,06396855 | 0,24881999 |
| 0,36574877 | 0,37182103 | 0,36705719 | 0,38303361 | 0,30886034 |
| 0,5090524 | 0,48775105 | 0,49231324 | 0,0868094 | 0,39545673 |
| 0,46924583 | 0,46618268 | 0,45766795 | 0,27020473 | 0,36081822 |
| 0,45066944 | 0,4446143 | 0,44967288 | 0,07770817 | 0,36514805 |
| 0,47455338 | 0,45270244 | 0,4523379 | 0 | 0,35648833 |
| 0,54885896 | 0,55515223 | 0,54294866 | 0,252838 | 0,46040397 |
| 0,61520323 | 0,60907317 | 0,60957422 | 0,09093801 | 0,52420953 |
| 0,66031733 | 0,65760202 | 0,66287467 | 0,13084243 | 0,57147487 |
| 0,5541665 | 0,57672061 | 0,55360875 | 0,34165276 | 0,5174574 |
| 0,46128452 | 0,46618268 | 0,46566302 | 0,18316672 | 0,40942251 |
| 0,53293633 | 0,52279967 | 0,52429351 | 0,17038038 | 0,45668778 |
| 0,49578354 | 0,50123129 | 0,49764328 | 0,12818128 | 0,45218632 |
| 0,54885896 | 0,54436804 | 0,54294866 | 0,16534263 | 0,48594726 |
| 0,59662683 | 0,59020084 | 0,60157916 | 0,22315475 | 0,52195886 |
| 0,64439471 | 0,67108226 | 0,64688454 | 0,54702621 | 0,59623268 |
| 0,66031733 | 0,66299411 | 0,66553969 | 0,11753419 | 0,58722987 |
| 0,59131929 | 0,57402456 | 0,58558902 | 0,22866335 | 0,51916604 |
| 0,63112586 | 0,61985736 | 0,61223925 | 0,22081923 | 0,53967721 |
| 0,62316454 | 0,60907317 | 0,62289933 | 0,09424167 | 0,60673839 |
| 0,74125734 | 0,75061564 | 0,72683521 | 0,19675089 | 0,69523847 |
| 0,84740818 | 0,83149706 | 0,80012332 | 0,93030193 | 0,80885381 |
| 0,81423604 | 0,8112767 | 0,81344843 | 0,03655379 | 0,77297524 |
| 0,88058031 | 0,86519765 | 0,87341144 | 0,12279397 | 0,82679283 |
| 0,83413932 | 0,82475694 | 0,82677355 | 0,10958841 | 0,80287405 |
| 0,77442948 | 0,76409588 | 0,76014799 | 0,07015382 | 0,72513728 |
| 0,68950881 | 0,67647435 | 0,68952489 | 0,03206518 | 0,66175207 |
| 0,79433276 | 0,77757612 | 0,7734731 | 0,16556637 | 0,73709694 |
| 0,89384917 | 0,87867788 | 0,88007399 | 0,01659602 | 0,84473225 |
| 0,88721474 | 0,885418 | 0,88007399 | 0,18904167 | 0,85905463 |
| 1 | 1 | 1 | 0,10809803 | 0,96222399 |
| 0,98673115 | 1 | 0,97334978 | 0,23874713 | 1 |
| 0,65500979 | 0,68995459 | 0,65221458 | 0,55266437 | 0,72027478 |
| 0,54355142 | 0,53358385 | 0,52162848 | 0,65424857 | 0,56907187 |
| 0,58601175 | 0,57941665 | 0,58825404 | 0,57048868 | 0,63459301 |
| 0,60193438 | 0,59828898 | 0,6069092 | 0,10210258 | 0,65223341 |
| 0,74125734 | 0,72365517 | 0,73349776 | 0,2232841 | 0,77319571 |

| Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|
| 0,70808521 | 0,68995459 | 0,68685987 | 0,52266696 | 0,72279487 |
| 0,617857 | 0,64142574 | 0,62289933 | 0,2593777 | 0,68499411 |
| 0,50374486 | 0,48775105 | 0,50030831 | 0,37897273 | 0,54639135 |
| 0,45066944 | 0,43922221 | 0,4523379 | 0,08558814 | 0,53769678 |

Setelah proses normalisasi dilakukan, data menunjukkan bahwa seluruh variabel telah berada pada skala yang seragam, sehingga tidak ada variabel yang mendominasi proses pembelajaran model. Dengan demikian, data hasil transformasi siap digunakan pada tahap pembagian data (*data splitting*) untuk pelatihan dan pengujian model ANN.

## 4.3 Pembagian Data

Dalam penelitian ini, dataset yang berjumlah 60 data bulanan dibagi menggunakan teknik *data splitting* dengan proporsi 80% untuk *data training* dan 20% untuk *data testing*. Pembagian ini menghasilkan 48 sampel data yang digunakan oleh model ANN untuk mempelajari pola dan menyesuaikan bobot secara optimal, sementara 12 sampel data sisanya digunakan sebagai instrumen validasi independen untuk menguji kemampuan generalisasi model terhadap data baru. Proporsi 80:20 dipilih guna menyeimbangkan kebutuhan model akan informasi yang cukup selama proses pembelajaran dengan kebutuhan evaluasi yang objektif untuk meminimalkan risiko *overfitting* pada dataset yang terbatas.

### 4.3.1 Data Training

Proses *training* merupakan proses pembelajaran *system neural-network* yang mengatur *input* dan pemetaan *output* sampai memperoleh model yang sesuai, sehingga terjadi pengaturan *wight* (bobot) dan bias. Proses ini meminimalkan kesalahan prediksi melalui iterasi berulang. Bobot dan bias yang tepat meningkatkan akurasi. Hasil data *training* terdiri dari 48 observasi yang terlampir pada Tabel 4.4.

**Tabel 4.4** Nilai Data Training

| No | Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|---|
| 1 | 0,623165 | 0,609073 | 0,622899 | 0,094242 | 0,606738 |
| 2 | 0,615203 | 0,609073 | 0,609574 | 0,090938 | 0,52421 |
| 3 | 0,794333 | 0,777576 | 0,773473 | 0,165566 | 0,737097 |
| 4 | 0,543551 | 0,533584 | 0,521628 | 0,654249 | 0,569072 |
| 5 | 1 | 1 | 1 | 0,108098 | 0,962224 |
| 6 | 0,847408 | 0,831497 | 0,800123 | 0,930302 | 0,808854 |
| 7 | 0,532936 | 0,5228 | 0,524294 | 0,17038 | 0,456688 |
| 8 | 0,834139 | 0,824757 | 0,826774 | 0,109588 | 0,802874 |

| No | Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|---|
| 9 | 0,617857 | 0,641426 | 0,622899 | 0,259378 | 0,684994 |
| 10 | 0,814236 | 0,811277 | 0,813448 | 0,036554 | 0,772975 |
| 11 | 0,308797 | 0,301462 | 0,310106 | 0,051777 | 0,250788 |
| 12 | 0 | 0 | 0 | 0,45019 | 0 |
| 13 | 0,29191 | 0,267149 | 0,266498 | 0,039863 | 0,205523 |
| 14 | 0,986731 | 1 | 0,97335 | 0,238747 | 1 |
| 15 | 0,378759 | 0,360284 | 0,368251 | 0,023289 | 0,276727 |
| 16 | 0,631126 | 0,619857 | 0,612239 | 0,220819 | 0,539677 |
| 17 | 0,65501 | 0,689955 | 0,652215 | 0,552664 | 0,720275 |
| 18 | 0,495784 | 0,501231 | 0,497643 | 0,128181 | 0,452186 |
| 19 | 0,330509 | 0,355382 | 0,314952 | 0,150518 | 0,280571 |
| 20 | 0,509052 | 0,487751 | 0,492313 | 0,086809 | 0,395457 |
| 21 | 0,689509 | 0,676474 | 0,689525 | 0,032065 | 0,661752 |
| 22 | 0,774429 | 0,764096 | 0,760148 | 0,070154 | 0,725137 |
| 23 | 0,106149 | 0,083331 | 0,094486 | 0,120406 | 0,059573 |
| 24 | 0,108561 | 0,090684 | 0,101754 | 0,078195 | 0,057652 |
| 25 | 0,591319 | 0,574025 | 0,585589 | 0,228663 | 0,519166 |
| 26 | 0,548859 | 0,544368 | 0,542949 | 0,165343 | 0,485947 |
| 27 | 0,503745 | 0,487751 | 0,500308 | 0,378973 | 0,546391 |
| 28 | 0,470433 | 0,450967 | 0,448201 | 0,08199 | 0,300278 |
| 29 | 0,509033 | 0,492633 | 0,506345 | 0,094508 | 0,3805 |
| 30 | 0,450669 | 0,444614 | 0,449673 | 0,077708 | 0,365148 |
| 31 | 0,393234 | 0,37744 | 0,334333 | 0,471064 | 0,261354 |
| 32 | 0,260548 | 0,245091 | 0,215621 | 0,242973 | 0,149894 |
| 33 | 0,469246 | 0,466183 | 0,457668 | 0,270205 | 0,360818 |
| 34 | 0,173698 | 0,16176 | 0,174435 | 0,139714 | 0,121068 |
| 35 | 0,365749 | 0,371821 | 0,367057 | 0,383034 | 0,30886 |
| 36 | 0,660317 | 0,657602 | 0,662875 | 0,130842 | 0,571475 |
| 37 | 0,470433 | 0,45832 | 0,380365 | 0,260644 | 0,278649 |
| 38 | 0,88058 | 0,865198 | 0,873411 | 0,122794 | 0,826793 |
| 39 | 0,318447 | 0,29656 | 0,305261 | 0,063969 | 0,24882 |
| 40 | 0,441483 | 0,426458 | 0,399746 | 0,277564 | 0,320927 |
| 41 | 0,741257 | 0,723655 | 0,733498 | 0,223284 | 0,773196 |
| 42 | 0,364284 | 0,37744 | 0,363406 | 0,281421 | 0,313766 |
| 43 | 0,554167 | 0,576721 | 0,553609 | 0,341653 | 0,517457 |
| 44 | 0,0193 | 0,051469 | 0,021804 | 1 | 0,042278 |
| 45 | 0,450669 | 0,439222 | 0,452338 | 0,085588 | 0,537697 |
| 46 | 0,123036 | 0,105389 | 0,121135 | 0,008883 | 0,082634 |
| 47 | 0,660317 | 0,662994 | 0,66554 | 0,117534 | 0,58723 |
| 48 | 0,893849 | 0,878678 | 0,880074 | 0,016596 | 0,844732 |

### 4.3.2 Data Testing

Sedangkan proses testing merupakan proses untuk menguji ketelitian dari model yang diperoleh dari proses *training*. Data testing terdiri dari 12 observasi yang digunakan untuk menguji kemampuan model dalam memprediksi data baru. Hasil *data testing* ditunjukkan pada Tabel 4.5.

**Tabel 4. 5** Nilai Data Testing

| No | Buka | Tinggi | Rendah | Volume | Target |
|---|---|---|---|---|---|
| 1 | 0,115799 | 0,112742 | 0,087217 | 0,304071 | 0,05573 |
| 2 | 0,369109 | 0,348029 | 0,34887 | 0,203088 | 0,272437 |
| 3 | 0,474553 | 0,452702 | 0,452338 | 0 | 0,356488 |
| 4 | 0,548859 | 0,555152 | 0,542949 | 0,252838 | 0,460404 |
| 5 | 0,461285 | 0,466183 | 0,465663 | 0,183167 | 0,409423 |
| 6 | 0,596627 | 0,590201 | 0,601579 | 0,223155 | 0,521959 |
| 7 | 0,644395 | 0,671082 | 0,646885 | 0,547026 | 0,596233 |
| 8 | 0,741257 | 0,750616 | 0,726835 | 0,196751 | 0,695239 |
| 9 | 0,887215 | 0,885418 | 0,880074 | 0,189042 | 0,859055 |
| 10 | 0,586012 | 0,579417 | 0,588254 | 0,570489 | 0,634593 |
| 11 | 0,601934 | 0,598289 | 0,606909 | 0,102103 | 0,652233 |
| 12 | 0,708085 | 0,689955 | 0,68686 | 0,522667 | 0,722795 |

## 4.4 Inisialisasi Bobot Awal

Pada penelitian ini, arsitektur jaringan yang digunakan terdiri dari satu *Hidden Layer* dengan jumlah 3 *neuron*. Penentuan jumlah neuron yang ringkas ini bertujuan untuk menjaga efisiensi model mengingat jumlah dataset yang terbatas agar terhindar dari *overfitting*. Proses pelatihan dilakukan dengan parameter *threshold* sebesar 0,01, di mana model secara otomatis mencapai konvergensi pada 254 *steps* (*epoch*).

Sebelum proses pelatihan dimulai, dilakukan inisialisasi nilai bobot dan bias awal yang ditentukan secara acak (*random*) oleh *software* R. Nilai-nilai bobot awal tersebut, yang menjadi titik awal bagi jaringan untuk mempelajari pola data saham BBRI, disajikan secara rinci pada Tabel 4.6 dan Tabel 4.7 sebagai berikut.

**Tabel 4. 6** Bobot Awal Hidden Layer

| Variabel | $W_{i,}^{(1)}$ | $W_{,k}^{(1)}$ | | |
|---|---|---|---|---|
| | | 1 | 2 | 3 |
| **Bias** | 1 | 0.96848929 | -0.57673001 | -1.4176367 |
| **Buka** | 2 | 1.96536781 | 0.72152335 | -1.7813108 |
| **Tinggi** | 3 | 0.88632253 | 0.61909890 | -0.6196351 |
| **Rendah** | 4 | 0.03054026 | 0.02100582 | 0.5085462 |
| **Volume** | 5 | 0.94955742 | 0.27485018 | -1.7529436 |

**Tabel 4.7** Bobot Awal Hidden Layer ke Output

| $W_{i,}^{(2)}$ | $W_{,k}^{(2)}$ |
|---|---|
| 1 | -1.4949038 |
| 2 | 0.2991750 |
| 3 | -0.3143986 |
| 4 | 0.9361277 |

## 4.5 Pelatihan Model *Artificial Neural Network*

Pelatihan *Backpropagation* ANN terdiri dari tiga fase: fase *feedforward*, fase *Backpropagation*, dan perubahan bobot. *Feedforward* dilakukan untuk mengetahui output *hidden layer* beserta nilai output, sedangkan *Backpropagation* dilakukan untuk menghitung koreksi bobot dan bias yang digunakan. Perubahan bobot ini dilakukan guna mencapai nilai *error* yang diharapkan.

Berikut hasil dari perhitungan bobot akhir pada *hidden layer* 1 terdapat pada Tabel 4.8 dan hasil bobot akhir pada *hidden layer* menuju *output* terdapat pada Tabel 4.9.

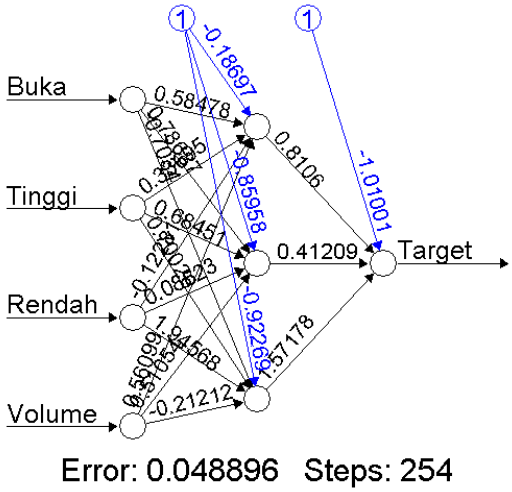
**Tabel 4.8** Bobot Akhir Hidden Layer 1

| **Variable** | $W_{i,}^{(1)}$ | $W_{,k}^{(1)}$ | | |
|---|---|---|---|---|
| | | **1** | **2** | **3** |
| **Bias** | 1 | -0.186966673 | -0.859578439 | -0.922687328 |
| **Buka** | 2 | 0.584778075 | 0.786872664 | -0.703400534 |
| **Tinggi** | 3 | 0.336951809 | 0.684509881 | 0.700259842 |
| **Rendah** | 4 | -0.122809255 | 0.088227012 | 1.945682584 |
| **Volume** | 5 | 0.560989604 | 0.510535793 | -0.212121099 |

**Tabel 4.9** Bobot akhir Hidden Layer ke Output

| **W[j,]** | **W[,l]** |
|---|---|
| | **1** |
| 1 | -1.010014748 |
| 2 | 0.810599250 |
| 3 | 0.412088397 |
| 4 | 1.571783917 |

Hubungan antara lapisan-lapisan dalam arsitektur yang digunakan selama proses pembelajaran adalah suatu jaringan di mana setiap unit sel pada satu lapisan terhubung sepenuhnya dengan unit-unit sel pada lapisan sebelumnya, sehingga bobot dan bias dari hubungan antar lapisan dapat ditentukan, keterhubungan ini memungkinkan pemrosesan informasi yang efisien dan akurat**, s**eperti yang ditunjukkan pada Gambar 4.1.




**Gambar 4.1** Plot Arsitektur ANN

Gambar 4.1 merupakan plot arsitektur ANN yang dihasilkan secara otomatis oleh *software* RStudio. Pada plot tersebut, garis berwarna hitam menunjukkan nilai bobot akhir (*final weights*) antar neuron, sedangkan garis berwarna biru menunjukkan nilai bias pada setiap lapisan.

Berdasarkan hasil pengolahan, model ini mencapai titik konvergensi pada iterasi ke-254 (*254 steps*). Angka ini merepresentasikan proses 'belajar' algoritma *Backpropagation* yang melakukan pembaruan bobot sebanyak 254 kali hingga mencapai batas toleransi kesalahan (*threshold*) sebesar 0.01. Hal ini membuktikan bahwa model telah melalui proses optimasi yang intensif untuk mengenali pola non-linear pada data saham BRI. Setiap bobot pada *input* dan *hidden layer* memiliki nilai positif dan negatif yang mencerminkan kekuatan hubungan antar variabel. Oleh karena itu, jika diinterpretasikan berdasarkan perhitungan yang telah dilakukan, rumusnya dapat dituliskan sebagai berikut:

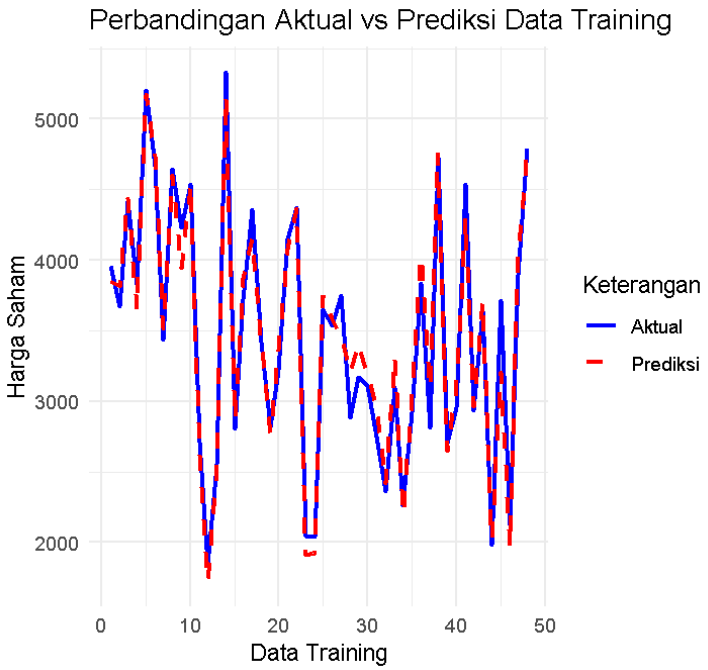
$$z_k = f(\sum_{i=1}^{4} u_{ik}x_i + u_{0k})$$

$$z_{ki} = f((0.584778075) * x_1 + (0.336951809) * x_2 + (-0.122809255) * x_3 + (0.560989604) * x_4 + (-0.186966673))$$

$$y_l = f(\sum_{i=1}^{j} z_j w_{ji} + w_{0l})$$

$$y_l = ((0.810599250) * z_{k1} + (0.412088397) * z_{k2} + (1.571783917) * z_{k3} + (-1.010014748))$$

$y_l$ merupakan output dari hasil prediksi nilai harga saham BRI ke l setelah melalui proses transformasi menggunakan fungsi aktivasi linear. Penggunaan fungsi linear ini memungkinkan model menghasilkan nilai kontinu yang sesuai dengan skala data harga saham. $w_{0l}$ merupakan bobot bias yang berfungsi sebagai konstanta penyeimbang, sedangkan $w_{jl}$ adalah bobot koneksi yang menghubungkan *hidden layer* dengan *output layer*. Nilai $z_{ki}$ sendiri merupakan nilai keluaran (*output*) dari setiap neuron pada *hidden layer* yang telah diaktifkan menggunakan fungsi sigmoid, yang kemudian menjadi masukan bagi *output layer* setelah dikalikan dengan bobot $w_{jl}$.




**Gambar 4.2** Plot Perbandingan Data *Training*

Berdasarkan hasil pengujian pada data training, diperoleh nilai $MAPE = 3{,}754\%$. Nilai ini menunjukkan bahwa tingkat kesalahan relatif model tergolong rendah, sehingga model *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* mampu mempelajari pola data harga saham dengan baik selama proses pelatihan.

## 4.6 Evaluasi Kinerja Model

### 4.6.1 Menghitung MSE

Menghitung MSE dilakukan menggunakan data testing sesuai pembagian data yang dilakukan sebelumnya. Nilai data aktual dan data prediksi yang digunakan untuk menghitung MSE didapat dari proses ANN *Backpropagation* seperti Tabel 4.10 berikut.

**Tabel 4.10** Perbandingan Nilai Aktual dan Prediksi dan Perhitungan MSE

| Indeks | Actual (y) | Prediction (t) | $yi - ti$ | $(yi - ti)^2$ |
|---|---|---|---|---|
| 1 | 2106,70337 | 2066,47279 | 40,23057923 | 1618,49951 |
| 2 | 2893,35034 | 2967,18683 | -73,83649206 | 5451,82756 |
| 3 | 3198,45752 | 3311,97731 | -113,5197872 | 12886,7421 |
| 4 | 3575,67114 | 3764,00545 | -188,334309 | 35469,812 |
| 5 | 3390,60864 | 3426,19648 | -35,5878389 | 1266,49428 |
| 6 | 3799,11597 | 3952,39151 | -153,275542 | 23493,3918 |
| 7 | 4068,72974 | 4266,60723 | -197,8774898 | 39155,501 |
| 8 | 4428,12109 | 4469,56327 | -41,44217861 | 1717,45417 |
| 9 | 5022,77344 | 4998,52184 | 24,25159659 | 588,139937 |
| 10 | 4207,97754 | 3998,72806 | 209,249476 | 43785,3432 |
| 11 | 4272,01221 | 3942,25268 | 329,7595258 | 108741,345 |
| 12 | 4528,15039 | 4374,34704 | 153,803354 | 23655,4717 |
| | | | **MSE** | **24.819,1685** |

Maka didapatkan hasil nilai MSE sebesar 24819,1685. Nilai *error* pada proses *training* dipengaruhi oleh beberapa hal, diantaranya adalah banyaknya percobaan dalam menetapkan *hidden layer*, menetapkan jumlah neuron serta menerapkan teknik pembelajaran pada jaringan yang direncanakan.

### 4.6.2 Menghitung MAPE

**Tabel 4.11** Perhitungan MAPE

| **Indeks** | **Actual** | **Prediction** | **Percentage Error (%)** |
|---|---|---|---|
| 1 | 2106,70337 | 2066,47279 | 2% |
| 2 | 2893,35034 | 2967,18683 | 3% |
| 3 | 3198,45752 | 3311,97731 | 4% |
| 4 | 3575,67114 | 3764,00545 | 5% |
| 5 | 3390,60864 | 3426,19648 | 1% |
| 6 | 3799,11597 | 3952,39151 | 4% |
| 7 | 4068,72974 | 4266,60723 | 5% |
| 8 | 4428,12109 | 4469,56327 | 1% |
| 9 | 5022,77344 | 4998,52184 | 0% |
| 10 | 4207,97754 | 3998,72806 | 5% |
| 11 | 4272,01221 | 3942,25268 | 8% |
| 12 | 4528,15039 | 4374,34704 | 3% |
| | | **MAPE** | **3%** |

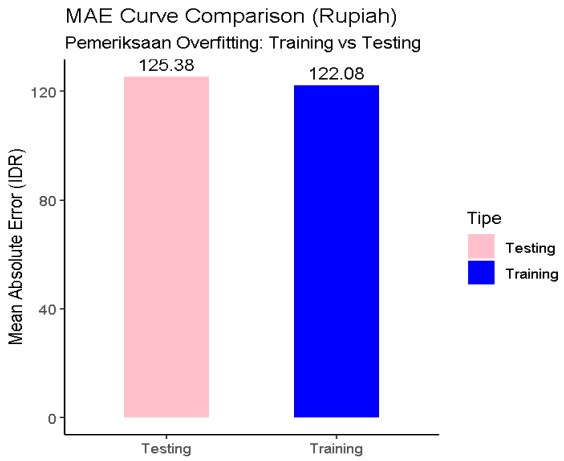
Berdasarkan hasil pengujian pada 12 data testing, diperoleh rata-rata nilai MAPE sebesar 3%. Hal ini menunjukkan bahwa rata-rata penyimpangan prediksi harga saham terhadap harga aktualnya hanya sebesar 3%. Mengacu pada kriteria kemampuan peramalan, model Neural Network yang dibangun dikategorikan memiliki kemampuan prediksi yang sangat akurat karena nilai MAPE berada di bawah 10%.

### 4.6.3 Pemeriksaan *Overfitting* dan *Underfitting*

Overfitting merupakan kondisi ketika model memiliki kinerja yang sangat baik pada data pelatihan (training), tetapi mengalami penurunan performa pada data pengujian (testing). Hal ini menunjukkan bahwa model terlalu menyesuaikan diri dengan pola pada data training dan kurang mampu melakukan generalisasi terhadap data baru.

Pada penelitian ini, evaluasi overfitting dilakukan dengan membandingkan nilai Mean Absolute Error (MAE) antara data training dan data testing. MAE digunakan karena mampu mengukur rata-rata kesalahan absolut antara nilai aktual dan nilai prediksi dalam satuan yang sama dengan data asli, sehingga mudah untuk diinterpretasikan.

Nilai MAE pada data training dihitung berdasarkan selisih antara nilai aktual dan hasil prediksi model terhadap data yang digunakan dalam proses pelatihan. Sementara itu, nilai MAE pada data testing dihitung menggunakan data yang tidak dilibatkan dalam proses pelatihan model. Perbandingan kedua nilai MAE tersebut digunakan sebagai indikator untuk menilai kemampuan generalisasi model.




**Gambar 4.3** Kurva MAE

Gambar 4.3 menunjukkan perbandingan nilai Mean Absolute Error (MAE) antara data training dan data testing. Hasil menunjukkan bahwa nilai MAE training sebesar 122,08 dan MAE testing sebesar 125,38. Perbedaan nilai error yang relatif kecil mengindikasikan bahwa model *Artificial Neural Network* (ANN) Backpropagation tidak mengalami

overfitting dan mampu melakukan generalisasi dengan baik terhadap data yang tidak dilibatkan dalam proses pelatihan.

## 4.7 Prediksi Nilai Harga Saham BRI

Setelah melalui tahap pengujian dan diperoleh nilai evaluasi berupa MSE serta MAPE yang menunjukkan tingkat akurasi sangat baik, model *Artificial Neural Network* (ANN) yang telah terlatih ini kemudian dapat digunakan untuk memprediksi harga saham BBRI. Untuk memberikan gambaran mekanisme kerja jaringan secara transparan, dilakukan simulasi perhitungan manual menggunakan data periode Desember 2024. Data input berupa nilai *Open, High, Low,* dan *Close* ($X_1$,$X_2$,$X_3$,$X_4$) yang telah dinormalisasi akan diproses menggunakan bobot akhir dan bias yang telah dihasilkan oleh model, dengan rincian perhitungan sebagai berikut:

$$z_{k1} = f\big((0.584778075) * (0.45066944) + (0.336951809) * (0.43922221) + (-0.122809255) * (0.4523379) + (0.560989604) * (0.08558814) + (-0.186966673)\big) = 0.2162$$

Fungsi Aktivasi:

$$z_1 = \frac{1}{1 + exp^{-0.2162}} = 0.5538$$

$$z_{k2} = f\big((0.786872664) * (0.45066944) + (0.684509881) * (0.43922221) + (0.088227012) * (0.4523379) + (0.510535793) * (0.08558814) + (-0.859578439)\big) = -0.1220$$

Fungsi Aktivasi:

$$z_2 = \frac{1}{1 + exp^{-(-0.1220)}} = 0.4696$$

$$z_{k3} = f\big((-0.703400534) * (0.45066944) + (0.700259842) * (0.43922221) + (1.945682584) * (0.4523379) + (-0.212121099) * (0.08558814) + (-0.922687328)\big) = -0.0690$$

Fungsi Aktivasi:

$$z_3 = \frac{1}{1 + exp^{-(-0.0690)}} = 0.4828$$

Nilai $z_{k1}$, $z_{k2}$, $z_{k3}$, adalah nilai *output* dari *input layer* ke *hidden layer* dan *output* pada *hidden layer* menjadi nilai *input* untuk mencari nilai *output* prediksi ($y_l$) berikut:

$$y_l = f\big((0.810599250) * (0.5538) + (0.412088397) * (0.4696) + (1.571783917) * (0.4828) + (-1.010014748)\big) = 0.5969$$

Hasil dari $y_l$ masih dalam rentang nilai normalisasi, sehingga perlu dilakukan denormalisasi yaitu:

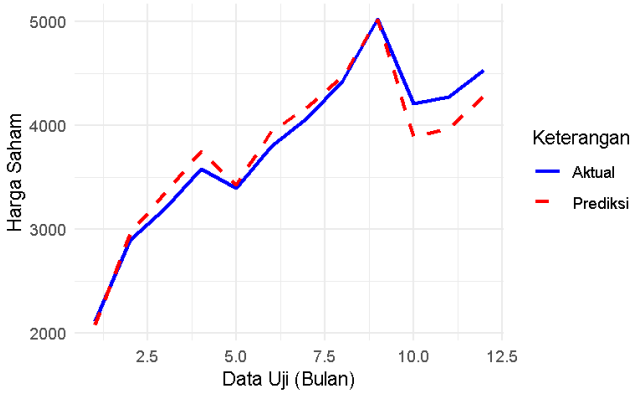
$$\begin{aligned} denorm &= y_l * \big(\max(target) - \min(target)\big) + \min(target) \\ &= 0.5969 * (5534.405 - 1904.404) + 1904.404 \\ &= 4071{,}25 \end{aligned}$$

Tahap denormalisasi dilakukan untuk mentransformasi kembali *output* jaringan dari skala 0-1 ke dalam satuan mata uang aslinya (Rupiah). Berdasarkan perhitungan manual yang telah dilakukan, diperoleh hasil prediksi harga penutupan saham BBRI yang telah disesuaikan untuk periode Januari 2025 sebesar Rp 4.071.25. Berdasarkan hasil pengujian terhadap keseluruhan data *testing*, model ini menghasilkan nilai MAPE sebesar 3 %, yang berarti tingkat akurasi model dalam memprediksi harga saham adalah sebesar 97%.

Perhitungan ini juga berlaku untuk periode berikutnya secara berkesinambungan. Sebagai contoh, untuk memprediksi harga pada bulan Januari 2025, model menggunakan data *Open, High, Low,* dan *Volume* periode Desember 2024 sebagai variabel *input*. Pola ini menunjukkan bahwa model memanfaatkan data historis satu bulan sebelumnya untuk memproyeksikan nilai harga saham pada masa mendatang."

## 4.8 Hasil Prediksi Nilai Harga Saham BBRI.JK

Setelah melalui proses pelatihan dan dilakukan uji pada data testing, dihasilkan hasil prediksi secara keseluruhan. Hasil prediksi akan dibandingkan dengan nilai aktual untuk mengertahui akurasi dari model ANN. Grafik dibandingkan dengan nilai aktual sebagai sumbu y dan nilai prediksi sebagai sumbu x. Hasil prediksi secara lengkap disajikan dalam gambar berikut.




**Gambar 4.4** Grafik Perbandingan Harga Saham Aktual vs Prediksi

Gambar 4.3 di atas mengilustrasikan bahwa model ANN dengan arsitektur 4-3-1 berhasil menangkap tren pergerakan harga aktual secara konsisten. Garis prediksi (garis

putus-putus) terlihat mampu mengikuti fluktuasi garis aktual (garis utuh) secara fleksibel. Kemampuan model untuk mengikuti grafik yang berkelok-kelok ini merupakan bukti nyata dari keunggulan algoritma *Backpropagation* dalam menangkap pola non-linear. Berbeda dengan model statistik konvensional yang cenderung kaku, *Backpropagation* secara iteratif memperbarui bobot pada *hidden layer* sehingga model dapat menyesuaikan diri dengan volatilitas harga saham yang dinamis.

Keunggulan Dibandingkan Model Tanpa *Hidden Layer* Penting untuk ditegaskan bahwa akurasi yang dicapai dalam penelitian ini merupakan kontribusi langsung dari penggunaan *hidden layer*. Apabila model dibangun tanpa menggunakan *hidden layer*, maka jaringan saraf tiruan tersebut hanya akan melakukan pemetaan linear yang identik dengan model Regresi Linear. Dalam kasus saham BBRI.JK yang memiliki banyak titik belok dan fluktuasi mendadak, model linear tanpa *hidden layer* dipastikan tidak akan mampu mengikuti gerakan harga yang kompleks karena hanya akan membentuk garis tren yang lurus atau terlalu sederhana. Sebaliknya, melalui fungsi aktivasi Sigmoid pada *hidden layer*, model ini mampu mentransformasi input *Open, High, Low,* dan *Volume* menjadi hasil prediksi yang jauh lebih akurat dan mendekati realitas pasar.

Secara numerik, kedekatan antara garis prediksi dan aktual pada plot tersebut didukung oleh nilai *error* yang sangat rendah. Berdasarkan hasil perhitungan, diperoleh nilai MAPE (Mean Absolute Percentage Error) sebesar 3%. Nilai MAPE yang berada di bawah 10% menunjukkan bahwa model memiliki kemampuan prediksi dengan kategori Sangat Baik. Meskipun terdapat deviasi kecil pada beberapa titik (seperti prediksi Januari 2025 yang menunjukkan angka Rp 4.071,25), model tetap konsisten dalam mengenali arah pergerakan pasar. Hal ini membuktikan bahwa penggunaan arsitektur ANN dengan satu lapisan tersembunyi sudah cukup optimal untuk memodelkan data *time series* saham yang bersifat non-linear dan fluktuatif.

# BAB V
# KESIMPULAN DAN SARAN

## 5.1 Kesimpulan

Berdasarkan hasil penelitian mengenai metode *ANN Backpropagation* dalam memprediksi harga saham penutupan Bank Rakyat Indonesia (BBRI.JK), dapat disimpulkan:

1. Model *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* berhasil dibangun menggunakan arsitektur 4-3-1 (empat variabel *input*, satu *hidden layer* dengan tiga neuron, dan satu neuron *output*). Arsitektur ini terbukti optimal dalam mentransformasi data historis menjadi prediksi harga yang relevan.
2. Keunggulan model ini terletak pada penggunaan *hidden layer* yang memungkinkan jaringan menangkap pola non-linear dan fluktuasi harga yang berkelok-kelok. Hal ini memberikan akurasi yang lebih tinggi dibandingkan model linear konvensional (seperti regresi linear), karena algoritma *Backpropagation* mampu melakukan penyesuaian bobot secara iteratif untuk mengikuti dinamika pasar yang kompleks.
3. Kinerja model ANN menunjukkan hasil yang sangat akurat, ditunjukkan oleh nilai *Mean Squared Error* (MSE) sebesar 24.819,1685 dan *Mean Absolute Percentage Error* (MAPE) sebesar 3%. Dengan nilai MAPE di bawah 10%, model ini masuk dalam kategori "Highly Accurate" (kemampuan prediksi sangat baik) dan layak digunakan sebagai alat bantu dalam analisis teknikal harga saham.

## 5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, penelitian selanjutnya disarankan untuk menggunakan jumlah data dan periode pengamatan yang lebih panjang agar model *Artificial Neural Network* (ANN) dapat mempelajari pola pergerakan harga saham secara lebih komprehensif. Selain itu, penambahan variabel lain seperti indikator teknikal, variabel makroekonomi, atau sentimen pasar dapat dipertimbangkan untuk meningkatkan akurasi prediksi. Penelitian berikutnya juga disarankan untuk mengeksplorasi variasi arsitektur ANN yang lebih beragam serta membandingkan kinerja ANN *Backpropagation* dengan metode prediksi lain guna memperoleh model yang lebih optimal.

# DAFTAR PUSTAKA


A. Wanto. (2018). Penerapan Jaringan Saraf Tiruan dalam Memprediksi Jumlah Kemiskinan pada Kabupaten/Kota di Provinsi Riau. *Kumpulan Jurnal Ilmu Komputer*, *5*(1), 61–74.

Ang, R. (2020). *Investasi Saham dan Manajemen Portofolio*. Salemba Empat.

Aris Puji Widodo, Suhartono, Eko Adi Sarwoko, & Zulfia Firdaus. (2017). Akurasi Model Prediksi Metode Backpropagation dengan Kombinasi Jumlah Neuron Tersembunyi dan Nilai Alpha. *Jurnal Matematika*, *20*(2), 79–84.

Aryanti, W. (2023). Penerapan Artificial Neural Network dengan Algoritma Backpropagation untuk Memprediksi Harga Saham . *Jurnal Riset Statistika (JRS)*, *3*(2), 107–108.

Aryanti, W., & Rifai, N. A. K. (2023). Penerapan Artificial Neural Network dengan Algoritma Backpropagation untuk Memprediksi Harga Saham. *Jurnal Riset Statistika*, 107–118. https://doi.org/10.29313/jrs.v3i2.2953

Czajkowski, M., & Kretowski, M. (2019). Decision tree underfitting in mining of gene expression data. An evolutionary multi-test tree approach. *Expert Systems with Applications*, *137*, 392–404. https://doi.org/10.1016/j.eswa.2019.07.019

Darmadji, T. (2011). *Pasar modal di Indonesia*. Salemba Empat.

Das, B., Nair, B., Reddy, V. K., & Venkatesh, P. (2018). Evaluation of multiple linear, neural network and penalised regression models for prediction of rice yield based on weather parameters for the west coast of India. *International Journal of Biometeorology*, *62*(10).

Effendi, M. (2017). *Analisis Teknikal Saham dan Pasar Modal.* . Alfabeta.

Fama, E. F., & French, K. R. (2015). A Five-Factor Asset Pricing Model. *Journal of Financial Economics*, *116*(1), 1–22.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Hermawan, A. (2006). Jaringan Syaraf Tiruan: Arsitektur dan Aplikasinya. In A. M (Ed.), *Jurnal Sains Komputasi* (Vol. 2, pp. 45–60). Universitas Indonesia Press.

Husnan, S. (2015). *Dasar-Dasar Manajemen Keuangan*. UPP STIM YKPN.

Innar Ridho, I., Fitri Ramadhani, C., & Perdana Windarto, A. (2023). Penerapan Artificial Neural Network dengan Metode Backpropagation Dalam Memprediksi Harga Saham (Kasus: PT. Bank BCA, Tbk) . *Jurnal Riset Sistem Informasi Dan Teknik Informatika*, *8*(1), 295–303.

Jiawei, H., & Kamber, M. (2006). *Data Mining Concepts and Techniques Second Edition* (2nd ed.). Elseiver.

Kasmir. (2016). *Analisis Laporan Keuangan*. RajaGrafindo Persada.

Kurniawan, R. (2024). *Harga Saham Melemah, Gimana Prospek Saham BBRI?* https://blog.rivankurniawan.com/2024/10/23/harga-saham-bbri-melemah/

LeCun, Y., & Hinton, G. E. (2015). Deep Learning. *Nature*, *521*(7553), 436–444.

Lesnussa, D. (2015). Penerapan Jaringan Syaraf Tiruan dalam Berbagai Masalah Teknik dan Industri. Jurnal Teknik Informatika. *Jurnal Teknik Informatika*, *9*(2), 45–57.

Monika, D., Wardani, S., Ahmad, A., & Solikhun. (2019). Model Jaringan Syaraf Tiruan dalam Memprediksi Ketersediaan Cabai Berdasarkan Provinsi. *Jurnal Teknik Informatika Dan Sistem Informasi*, *8*(1), 17–24.

*Neural networks and learning machines (3rd ed.): Vol. Haykin, Simon* (3rd ed.). (2016). Pearson.

Peng, Y., & Nagata, M. H. (2020). An empirical overview of nonlinearity and overfitting in machine learning using COVID-19 data. *Chaos, Solitons & Fractals*, *139*, 110055. https://doi.org/10.1016/j.chaos.2020.110055

Santoso, A., & Hansun, S. (2019). Prediksi IHSG dengan Backpropagation Neural Network. *Jurnal Rekayasa Sistem Dan Teknologi Informasi*, *3*(2), 313–318.

Sebayang, J. S., & Yuniarto, B. (2017). Perbandingan Model Estimasi Artificial Neural Network Optimasi Genetic Algorithm dan Regresi Linier Berganda. *MEDIA STATISTIKA*, *10*(1), 13. https://doi.org/10.14710/medstat.10.1.13-23

Setiawan Nugraha, E., & Jovanie Sitepu, G. (2022). A Backpropagation Artificial Neural Network Approach for Loan Status Prediction. *Jurnal Teknik Informatika*, *15*(2), 147–158.

Setti, S., & Wanto, A. (2019). Analysis of backpropagation algorithm in predicting the most number of internet users in the world. *Jurnal Online Informasi*, *3*(2), 110.

Windarto, A. P. (2017a). Implementasi JST dalam menentukan kelayakan nasabah pinjaman KUR pada Bank Mandiri Mikro Serbelawan dengan metode backpropagation. *Jurnal Sains Komputasi Dan Informatika*, *1*(1), 12–23.

Windarto, A. P. (2017b). Implementation of data mining on rice imports by major country of origin using K-means clustering method. *International Journal of Artificial Intelligence Research*, *1*(2), 26–33.

# LAMPIRAN

## Lampiran 1

```
### IMPORT LIBRARY ###
library(quantmod)
library(dplyr)
library(lubridate)
library(openxlsx)
library(neuralnet)
library(ggplot2)
library(psych)

### IMPORT DATA ###
## Ambil data BBRI ##
getSymbols("BBRI.JK", src = "yahoo", from = "2020-01-01", to = "2024-12-
31")
data <- data.frame(Date = index(BBRI.JK), coredata(BBRI.JK))
data <- data[, -5]
View(data)

## Data Selection ##
# Ambil tanggal perdagangan terakhir setiap bulan
data_bulanan <- data %>%
  group_by(bulan = floor_date(Date, "month")) %>%  # grup berdasarkan bu
lan
  slice_tail(n = 1) %>%                            # ambil baris terakhi
r per bulan
  ungroup() %>%
  dplyr::select(-bulan)
colnames(data_bulanan) <- c("Tanggal", "Buka", "Tinggi", "Rendah", "Volu
me", "Target")
View(data_bulanan)

### ANALISIS DESKRIPTIF ###
# Statistik deskriptif tiap kolom
describe(data_bulanan[,(-1)])

### PREPROCESSING DATA ###
## Data Cleaning ##
# Pengecekkan Data Missing
is.na(data_bulanan)
sum(is.na(data_bulanan))

# Pengecekkan Data Duplikat
any(duplicated(data_bulanan))

## Data Transformation ##
# normalisasi data
maxs <-apply(data_bulanan[,-1], 2, max)
mins <-apply(data_bulanan[,-1], 2, min)
normalize<-function(x){return((x-min(x))/((max(x)-min(x))))}

scaled <-as.data.frame(scale(data_bulanan[,-1], center = mins, scale = m
axs - mins))
View(scaled)

### Data Splitting ###
# pemisahan acak split data train dan data testing 80:20 #
set.seed(500)
index <-sample(1:nrow(scaled),round(0.8*nrow(scaled)))

# Pemisahan data asli #
train <-data_bulanan[index,]
test <-data_bulanan[-index,]
```

```
# pemisahan data normalisasi #
train_<-scaled[index,]
test_<-scaled[-index,]
print(paste("Data Latih:", nrow(train_)))
print(paste("Data Uji:", nrow(test_)))
View(train_)
View(test_)

### PELATIHAN NEURAL NETWORK ###
set.seed(500)
nn <-neuralnet(Target~Buka+Tinggi+Rendah+Volume,
               data=train_,
               hidden=c(3),
               linear.output = T,
               threshold = 0.01)
print(nn)

# plot dan cek weights #
plot(nn)
nn$startweights
nn$result.matrix

# uji output yang dihasilkan #
temp_test<-subset(test_, select =c("Buka","Tinggi","Rendah","Volume"))
temp_test

# menghitung prediksi #
nn.results <- compute(nn, temp_test)
results <- data.frame(actual=test_$Target, prediction=nn.results$net.res
ult)
View(results)

### DENORMALISASI ###
max_target <- maxs["Target"]
min_target <- mins["Target"]

# mengembalikan nilai ke harga asli #
actual_values <- (results$actual * (max_target - min_target)) + min_targ
et
predictions <- (results$prediction * (max_target - min_target)) + min_ta
rget

# Buat dataframe hasil akhir untuk evaluasi
results_final <- data.frame(
  Indeks = 1:nrow(test_),
  Actual = actual_values,
  Prediction = predictions
  )
View(results_final)

### MENGHITUNG ERROR (MSE & MAPE & MAE) ###
MSE <-sum((results_final$Actual - results_final$Prediction)^2)/nrow(resu
lts_final)
MAPE <- mean(abs((results_final$Actual - results_final$Prediction) / res
ults_final$Actual)) * 100
cat("Mean Squared Error (MSE):", MSE, "\n")
cat("Mean Absolute Percentage Error (MAPE):", MAPE, "%\n")

pred_train_scaled <- compute(nn, train_[,1:4])$net.result
pred_train_rp <- (pred_train_scaled * (max_target - min_target)) + min_t
arget
act_train_rp <- (train_$Target * (max_target - min_target)) + min_target
mae_train <- mean(abs(act_train_rp - pred_train_rp))
mae_test <- mean(abs(actual_values - predictions))
cat("MAE Training: ", mae_train, "\n")
cat("MAE Testing : ", mae_test, "\n")

mae_comparison <- data.frame(
  Tipe = c("Training", "Testing"),
```

```
  Nilai_MAE = c(mae_train, mae_test)
)
ggplot(mae_comparison, aes(x = Tipe, y = Nilai_MAE, fill = Tipe)) +
  geom_bar(stat = "identity", width = 0.5) +
  geom_text(aes(label = round(Nilai_MAE, 2)), vjust = -0.5) +
  scale_fill_manual(values = c("Training" = "blue", "Testing" = "pink"))
+
  labs(title = "MAE Curve Comparison (Rupiah)",
       subtitle = "Pemeriksaan Overfitting: Training vs Testing",
       y = "Mean Absolute Error (IDR)",
       x = "") +
  theme_classic()

### VISUALISASI ###
# Plot actual vs. predicted values
ggplot(results_final, aes(x = Indeks)) +
  geom_line(aes(y = Actual, color = "Aktual"), size = 1) +
  geom_line(aes(y = Prediction, color = "Prediksi"), linetype = "dashed
", size = 1) +
  labs(title = "Perbandingan Harga Saham BBRI: Aktual vs Prediksi",
       x = "Data Uji (Bulan)",
       y = "Harga Saham") +
  scale_color_manual(name = "Keterangan", values = c("Aktual" = "blue",
"Prediksi" = "red")) +
  theme_minimal()

list_laporan <- list("Data Normalisasi" = scaled,
                     "Data Training" = train_,
                     "Data Testing" = test_,
                     "Hasil Prediksi" = results_final
                     )
```